

Masterarbeit

Untersuchung der Integrationsmöglichkeiten deterministischer Modelle in die GAN-Routine zur Analyse von OCT-Signalen

Zur Erlangung des Grades

Master of Science

im Studiengang Medizin- und Gesundheitstechnologie

an der Fakultät Physikalische Technik / Informatik

der Westsächsischen Hochschule Zwickau

eingereicht von

Maksim Meshkov

geboren am 17. Juni 2001

Gutachter:

Prof. Dr. rer. nat. habil. Peter Hartmann

Betreuer:

M. Eng. Alexander Kabardiadi-Virkovski

Ausgabedatum:

17. März 2025

Eingereicht am:

17. September 2025

Autorenreferat

Die Arbeit untersucht die Integration eines deterministischen Ansatzes in ein neuronales Netz-basiertes Modell zur Analyse von OCT-Signalen. Die Entwicklung des Modells erfolgt unter Verwendung der GAN-Architektur. Der Datensatz für das Lernen eines neuronalen Netzwerks wird durch einen deterministischen Algorithmus generiert. Nach dem Training ist das modifizierte Modell in der Lage, grundlegende physikalische Muster im Signal zu erkennen und zu reproduzieren. Die Einbindung des deterministischen Algorithmus hat die Einsatzmöglichkeiten des Modells erweitert. Es kann nun für unterschiedliche Quellenbereiche und Parameter des verwendeten OCT-Systems angewendet werden, was die Analyse interferometrischer Signale in Medizin und Industrie erleichtert.

Schlüsselwörter: OCT, neuronales Netz, GAN, deterministischer Ansatz, interferometrisches Signal

Abstract

This thesis investigates the integration of a deterministic approach into a neural network-based model for the analysis of OCT signals. The model is developed using a GAN architecture. The dataset for training the neural network is generated by a deterministic algorithm. After training, the modified model is capable of recognizing and reproducing fundamental physical patterns in the signal. The incorporation of the deterministic algorithm has expanded the model's applicability. It can now be applied to different source ranges and parameters of the OCT system used, facilitating the analysis of interferometric signals in medicine and industry.

Keywords: OCT, neural network, GAN, deterministic approach, interferometric signal

Danksagung

Ich möchte allen Beteiligten danken, die mich bei der Anfertigung meiner Masterarbeit unterstützt haben.

Mein besonderer Dank gilt Herrn Prof. Dr. rer. nat. habil. Peter Hartmann, der es mir ermöglicht hat, diese Arbeit unter seiner Gutachtertätigkeit am Fraunhofer Anwendungszentrum in Zwickau zu schreiben.

Ebenso möchte ich Herrn M. Eng. Alexander Karbadiadi-Virkovski danken, mit dem ich unzählige lange Gespräche geführt habe. Dank all seiner ausführlichen Erklärungen habe ich viel gelernt und war in der Lage, eine Arbeit dieses Umfangs zu erstellen.

Besonderer Dank gilt auch den Mitarbeitern des Fraunhofer Anwendungszentrums AZOM, die mir bei auftretenden Schwierigkeiten während der Erstellung der Arbeit stets hilfsbereit zur Seite standen. Hervorheben möchte ich Josephin Bischoff, an die ich mich jederzeit mit Ratfragen wenden konnte.

Schließlich wäre all dies nicht möglich gewesen ohne meine Familie. Ohne ihre Unterstützung und ihr Vertrauen in mich hätte ich nicht das erreichen können, was ich geschafft habe.

Inhaltsverzeichnis

1	Einleitung und Motivation	1
2	Theoretische Grundlagen	4
2.1	Grundlagen der Weißlichtinterferometrie	4
2.1.1	Zeitbereich-Weißlichtinterferometrie	8
2.1.2	Fourierbereich-Weißlichtinterferometrie	10
2.1.3	Optische kohärente Tomographie	17
2.2	Inverse Aufgaben	18
2.3	Herausforderungen bei der digitalen Signalverarbeitung	19
2.3.1	Abtastung der Signal	19
2.3.2	Metrik	21
2.3.3	Rauschen	22
2.4	Maschinelles Lernen(ML)	23
2.4.1	Kernbegriffe des maschinellen Lernens	24
2.4.2	Generatives Netzwerk am Beispiel von CycleGAN	26
3	Modellentwicklung und Implementation	29
3.1	Anwendungsfall Profilometrie	30
3.1.1	Ideales Signal	31
3.1.2	Dispersion im Signal	46
3.1.3	Signalrauschen	52
3.1.4	Integration des deterministischen Ansatzes in CycleGAN	53
3.2	Anwendungsfall Tomographie	54
3.2.1	Generierung von Daten	55

3.2.2	Transformation $J: A \rightarrow B$	62
3.2.3	Transformation $Q: B \rightarrow A$	63
3.2.4	Geschlossener Transformationszyklus(CycleGAN) - Kombination von J und Q	64
4	Zusammenfassung der Ergebnisse	65
5	Ausblick	66
6	Anhang	72

Abbildungsverzeichnis

1.1	Vereinfachtes Schema des Interferometrieprozesses zur Gewinnung von Informationen über die Probe. Q – Lichtquelle, IM – Michelson-Interferometer, P – Probe, IS – interferometrisches Signal, FFT – schnelle Fourier-Transformation. .	1
2.1	Schematische Darstellung des Youngschen Doppelspaltexperiment zur Demonstration der Welleninterferenz. LQ – monochromatische Lichtquelle, DS – Doppelspalte, S – Beobachtungsschirm, IB – Interferenzbild	4
2.2	Interferenz eines Strahls an einem dünnen Schicht. LQ – monochromatisches Lichtquelle, SC – dünne Schicht, S – Schirm, S_1 – erster Strahl S_2 – zweiter Strahl. ω – Kreisfrequenz der Quelle, n_1 – Brechungsindex der Luft, n_2 – Brechungsindex der Schicht, n_3 – Brechungsindex des Substrats, h – Dicke der Schicht, θ – Ausbreitungswinkel in der Schicht	5
2.3	Schema des Michelson-Interferometers: L – Lichtquelle, ST – Strahlteiler, R – Referenzspiegel, P – Probe, IS – Interferenzsignal, SM – Spektrometer. L_r und L_p bezeichnen die Armlängen des Interferometers. E steht für das Quellfeld, während E_r und E_p die elektrischen Felder in den beiden Armen darstellen. . .	6
2.4	Schema der Michelson-Interferometer-Konfiguration für Untersuchungen im Zeitbereich. ST – Strahlteiler, R – Referenzspiegel, P – Probe, IS – Interferenzsignal, D – Detektor. L_r und L_p bezeichnen die Armlängen des Interferometers. ΔL_r bezeichnet eine Änderung der Schulterlänge	8
2.5	Schematische Darstellung einer einzelnen, vereinfachten CCD-Zelle. S — Steuerelektrode, D — dielektrische Schicht, PT — Potentialtopf	9
2.6	Schema der Michelson-Interferometer-Konfiguration für Untersuchungen im Fourierbereich. R – Referenzspiegel, P – Probe, ST – Strahlteiler, IS – Interferenzsignal, SM – Spektrometer, K – Kollimatorsystem, D – Detektor, G – Beugungsgitter. L_r und L_p bezeichnen die Armlängen des Interferometers . . .	10
2.7	Beispiel eines simulierten typischen Interferogramms in der Weißlichtinterferometrie, erfasst am Detektor	10

2.8	Die Reflexion einer elektromagnetischen Welle E an einer geschichteten Probe mit $(m + 1)$ Schichten. ST – Strahlteiler, P – Probe. d_0 ist der Abstand vom ST bis zur Oberfläche der Probe(P), während d mit dem Index m die Schichtdicken beschreibt. Die Parameter, die eine Schicht charakterisieren, sind: a – Dämpfungskoeffizient nach Absorption, r – Reflexionskoeffizient(Fresnel-Koeffizient), k – Wellenvektor des Mediums, sowie φ – die Phasenänderung bei der Reflexion. .	11
2.9	Abhängigkeit der Komponenten des Brechungsindex von der Anregungsfrequenz ($e = 1,602 \times 10^{-19}$ C, $m = 9,109 \times 10^{-31}$ kg, $\varepsilon_0 = 8,854 \times 10^{-12}$ F/m, $f_0 = 1,5 \times 10^{15}$ Hz, $\gamma_f = 1 \times 10^{14}$ Hz)	15
2.10	Schema des Michelson-Interferometers mit einem Dispersionselement in Referenzarm. R – Referenzspiegel, P – Probe, ST – Strahlteiler, IS – Interferenzsignal, SM – Spektrometer. L_r und L_p bezeichnen die Armlängen des Interferometers. n ist der Brechungsindex des Dispersionselements und L_n dessen Länge	16
2.11	Beispiel der Fourier-Transformation des Interferogramms einer typischen mehrschichtigen Probe. Die Abbildung zeigt nur die Amplitude des Fourier-Spektrums	17
2.12	Visualisierung der drei Scan-Typen in der OCT. A-Scan – Eindimensionales Tiefenscanning entlang der z-Achse. B-Scan – Zweidimensionales Bild, erzeugt durch Aufeinanderfolge von A-Scans entlang der x-Achse. C-Scan – Dreidimensionales Volumenscanning, erweitert die B-Scans durch zusätzliche Bewegung entlang der y-Achse. P – Größe des Objekts entlang der x-Achse, Q – Größe des Objekts entlang der y-Achse, N – Scan-Schritt.[42]	17
2.13	Demonstration des Aliasing-Effekts bei zu großem Abtastschritt	21
2.14	Vergleich verschiedener Rauschtypen mit angepassten Parametern: $R = 6,04 \times 10^{16} \Omega$, $I = 4,30 \times 10^{-19}$ A, $A = 2,51 \times 10^{-1}$	23
2.15	Ein vereinfachter Algorithmus zur Modellentwicklung im Rahmen des maschinellen Lernens zur Generalisierung von Daten. D – Menge der Ausgangsdaten, M – ausgewähltes mathematisches Modell, F – Berechnung der Abweichungen der Vorhersagen von den Ausgangsdaten, P – Prozess der Kalibrierung der Parameter des mathematischen Modells.	24
2.16	Schema eines Neurons eines künstlichen neuronalen Netzes. Den Eingabewerten x werden Gewichtswerte w_k zugewiesen, die anschließend summiert und durch eine Aktivierungsfunktion φ geleitet werden. y – Ausgangswerte des Neurons. .	25
2.17	Beispiel für die Anwendung der Faltung auf ein zweidimensionales Datenarray. I – Ausgangsmatrix, K – Faltungskern (Kernel), IK – Ausgabematrix der Faltungsoperation[32]	25

2.18	Beispiel für die Anwendung der Faltung auf ein	26
2.19	Schema eines einfachen GAN-Netzwerks mit Generator und Diskriminator . .	27
2.20	Schema von CycleGAN[54]	27
3.1	Schema des entwickelten Algorithmus zur Verarbeitung von Signalen in der Weißlichtinterferometrie. 1 – Pfad der Transformation der Probenparameter in die entsprechenden Spektren, 2 – Pfad der Transformation des Spektrums in die Probenparameter, auf deren Grundlage es erzeugt wurde. Δ – optische Weglängendifferenz, die die Position der reflektierenden Oberfläche des untersuchten Objekts charakterisiert.	29
3.2	Schema des Datengenerators in Python. FFT – schnelle Fourier-Transformation	31
3.3	Kosinusfunktion in Abhängigkeit von φ bei einem Wert von $\Delta = 22 \mu\text{m}$	32
3.4	Fourier-Bild der Kosinusfunktion für $\Delta = 22 \mu\text{m}$. Die vertikale Achse stellt die Amplitude der Fourier-Transformation $ F(1/\omega) $ dar.	32
3.5	Schematische Darstellung der Kombination zweier Transformationsnetzwerke der Domänen A und B in einem CycleGAN. G – Funktion zur Transformation des Spektrums in den Wert der optischen Weglängendifferenz Δ , F – Funktion zur Rücktransformation von Δ in das Spektrum	33
3.6	Schema der G-Transformation für ein einzelnes Spektrum. Conv2d – Faltungsoperation, Flatten – Vektorisierung, Linear – vollständig verbundene Schicht. .	34
3.7	Das Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Transformation («Epoch» = 30, «Learning rate» = 10^{-3}). Alle Werte wurden gemäß Formel 3.4 normalisiert.	35
3.8	Schema der F-Transformation für einen einzelnen Wert der optischen Wegdifferenz. Linear – vollständig verbundene Schicht, ConvTransposed2d – transponierte Faltungsoperation.	36
3.9	Das Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die F-Umwandlung («Epoch» = 50, «Learning rate» = 10^{-4}). Beide Spektren wurden für den Wert der optischen Wegdifferenz $\Delta = 22 \mu\text{m}$ erzeugt. Der Wert der vertikalen Achse der Amplitude ist gemäß Formel 3.4 normalisiert, während die horizontale Achse stellt die nach FFT in den positiven Bereich verschobenen Frequenzen f dar.	37

3.10	Visualisierung polare Fälle der Spektrumsvorhersage durch Netzwerk F(«Epoch» = 50, «Learning rate» = 10^{-4}). a – Spektren wurden bei $\Delta = 1 \mu\text{m}$ erzeugt. b – Spektren wurden bei $\Delta = 100 \mu\text{m}$ erzeugt. Blaue Linie - wahres Spektrum, rote Linie - vorhergesagtes Spektrum.	38
3.11	a – Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Umwandlung in CycleGAN(«Epoch» = 20, «Learning rate» = 10^{-5}). b – Vergrößerung des Diagrammbereichs mit Werten für Δ zwischen 0 und 10	38
3.12	a – simuliertes Spektrum nach FFT für $\Delta = 2 \mu\text{m}$. b – simuliertes Spektrum nach FFT für $\Delta = 10 \mu\text{m}$	39
3.13	Darstellung des $\text{rect}\left(\frac{t}{T}\right)$ mit dem Parameter $T=2$	40
3.14	Darstellung des Kardinalsinus mit dem Parameter $T=2$	41
3.15	Darstellung der Gaußfunktion	43
3.16	Darstellung der Gaußfunktion im Zeitbereich	44
3.17	Das Ergebnis der Multiplikation des Kosinus mit der Gauß-Funktion	44
3.18	Ergebnis der Anwendung der Gauß-Funktion auf das Signal. a – simuliertes Spektrum für $\Delta = 2$ nach Multiplikation mit Gauss-Funktion, b – simuliertes Spektrum für $\Delta = 10$ nach Multiplikation mit Gauss-Funktion	45
3.19	Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Umwandlung in CycleGAN für Δ zwischen 0 und 10(«Epoch» = 2, «Learning rate» = 10^{-5}).	45
3.20	Vergleich der Vorhersageergebnisse der Spektren nach Multiplikation mit der Gauß-Funktion durch das Netzwerk für die Transformation F («Epoch» = 50, «Learning rate» = 10^{-4}). Die x-Achse ist so skaliert, dass der Hauptteil der Generierung – die beiden Peaks – sichtbar wird. a – Spektren für $\Delta = 2 \mu\text{m}$, b – Spektren für $\Delta = 10 \mu\text{m}$. Blaue Linie – wahres Spektrum, rote Linie – vorhergesagtes Spektrum.	46
3.21	Abhängigkeit des Brechungsindex von N-BK7-Glas von der Wellenlänge	47
3.22	Abhängigkeit des Brechungsindex von der Wellenlänge für verschiedene Materialien. a – Kohlenstoffdisulfid (CS_2), b – Fused Silica, c – MDMO-PPV.	47
3.23	Simulationsergebnis des Signals nach Formel 3.16 für drei verschiedene Materialien auf Basis experimenteller Daten $n(\lambda)$. a – Kohlenstoffdisulfid (CS_2), b – Fused Silica, c – MDMO-PPV.	47

3.24	Beispiel eines verzerrten Spektrums für $\Delta = 50 \mu\text{m}$. Die oszillierenden Signalanteile überlagern sich und erzeugen damit eine rauschähnliche Struktur. . . .	48
3.25	Die Ableitung des Brechungskoeffizienten für N-BK-7 von der Wellenlänge . .	49
3.26	Phasenableitung in Abhängigkeit von der Wellenlänge bei $\Delta = 22 \mu\text{m}$	49
3.27	Zulässige Änderung des Wellenlängenschritts gemäß Nyquist-Kriterium zur verzerrungsfreien Signalverarbeitung	50
3.28	Beispiel für die Erweiterung des Bereichs der Erzeugung unverzerrter Spektren durch Anwendung der Gauß-Funktion. a – simuliertes Spektrum mit Gauß-Filterung für $\Delta = 100 \mu\text{m}$, b – simuliertes Spektrum mit Gauß-Filterung für $\Delta = 170 \mu\text{m}$	51
3.29	Demonstration des Aliasing-Effekts am Beispiel des Fourier-Spektrums bei $\Delta > 1000 \mu\text{m}$	51
3.30	Demonstration der spektralen Leistungen des simulierten weißen Rauschens (thermischer Anteil) und des rosa Rauschens ($1/f$ Flicker-Rauschanteil). Die spektrale Leistung ist in willkürlichen Einheiten (a.u.) nach Fourier-Transformation dargestellt.	52
3.31	Einfügen von Rauschen in die Simulation des Interferogramms.	52
3.32	Einfluss von Rauschen auf die Fourier-Spektren. a – Simulation des Spektrums mit Rauschen ohne Multiplikation mit einer Gaußfunktion, b – Simulation des Spektrums mit Rauschen und Multiplikation mit einer Gaußfunktion. Rauschamplitude – 0,4	53
3.33	Schema der Implementierung des deterministischen Algorithmus in die Architektur von CycleGAN. G und F' – Transformationsfunktionen. Conv2d – Faltungsoperation, Flatten – Vektorisierung, Linear – vollständig verbundene Schicht.	53
3.34	Ergebnisse nach dem Training des Neuralnetzwerks G im CycleGAN mit deterministischer Algorithmus («Epoch» = 25, «Learning rate» = 10^{-3}). Parameter des deterministischen Algorithmus: Strahlungsquelle – $[0,2-6,7 \mu\text{m}]$ mit einer Auflösung von 6 nm , Dispersionselement – Fused Silica mit einer linearen Größe von 1 cm, Gauß-Funktion als Filter mit Wirkungsbereich – $[1,2-2,0 \mu\text{m}]$, Rauschamplitude – 0,8. Relative Vorhersagefehler $<< 1\%$	54

3.35	Flussdiagramm des verwendeten Skripts zur Simulation OCT-Bilder. NA – Numerische Apertur, SNR – Signal-Rausch-Verhältnis, ρ – Dichte der Streuer, r – Radius der Streuer, n – Brechungsindex der Streuer	56
3.36	Ein Beispiel zur Visualisierung der Ergebnisse des Skripts von Sebastian Ruiz Lopera. a – Profilkarte der Rückstreuung für die geschichtete Struktur, b – OCT-B-Scan.	56
3.37	Rückstreuprofil eines Schnitts einer geschichteten Probe. Die Intensität des Signals im Rückstreuprofil wird in willkürlichen Einheiten (a.u.) angegeben. Die Einheiten sind nicht kalibriert und entsprechen nicht der absoluten Leistung. . .	57
3.38	Simuliertes Interferogramm im Spektralraster im Wellenzahlraum k , das vom Spektrometer des OCT-Systems registriert wird.	58
3.39	Vergleich der Hanning-Fensterfunktion mit der Gauß-Funktion. Die Grenzen der Funktionen entsprechen den ursprünglich festgelegten Parametern des Quellspektrums $\Delta\lambda$	58
3.40	Amplitude der Fourier-transformierten Interferogramm-Funktion	59
3.41	Phase der Fourier-transformierten Interferogramm-Funktion	59
3.42	a – Amplitudenkomponente des B-Scans basierend auf den Interferogrammen, b – Phasenkomponente des B-Scans	59
3.43	Modell zur Faltung der Amplituden- und Phasenteile des B-Scans zu einem eindimensionalen Vektor mit Parametern der Schichtgenerierung. Conv2D – Faltungsoperation für 2D. AdaptiveAvgPool2d – adaptives Mittelwert-Pooling für 2D. Flatten – Vektorisierung, Concatenation – Konkatenation. Linear – vollständig verbundene Schicht.	61
3.44	Beispiel für den Vergleich der Vorhersagen des Faltungsmodells für Amplitude und Phase mit den tatsächlichen Parametern, die in einem eindimensionalen Vektor gespeichert sind.	61
3.45	CycleGAN-Schema zur Transformation der Amplituden- und Phasenkomponente des OCT-B-Scans (A) in die Karte der Rückstreuprofile (B). J und Q bezeichnen die Funktionen zur Transformation der Daten von einer Domäne in die andere.	62
3.46	Schema der Funktion J zur Transformation der Amplituden- und Phasenkomponente des OCT-B-Scans in die Karte der Rückstreuprofile. Conv2d – Faltungsoperation, ConvTransposed2d – transponierte Faltungsoperation.	62

3.47	Ergebnis der Funktion J. a – tatsächliches Rückstreuprofil, b – vorhergesagtes Profil.	63
3.48	Schema der Funktion Q zur Transformation der Karte der Rückstreuprofile in die Amplituden- und Phasenkomponente des B-Scans. Conv2d – Faltungsoperation.	63
3.49	Ergebnis der Funktion Q. a – tatsächliche Amplitude des B-Scans, b – tatsächliche Phase des B-Scans, c – vorhergesagte Amplitude, d – vorhergesagte Phase.	64
3.50	Ergebnisse des Trainings- und Validierungsprozesses der J- und Q-Netze im Zyklus. Epoch – ein vollständiger Durchlauf durch den gesamten Trainingsdatensatz. Loss – relative Abweichung der Vorhersagen von den tatsächlichen Werten.	64

Abkürzungsverzeichnis

OCT	Optische Kohärenztomographie
GAN	Generative Adversarial Network
FFT	Schnelle Fourier-Transformation
ML	Maschinelles Lernen
MDMO-PPV	$[(C_{19}H_{28}O_2)_n]$

Symbolverzeichnis

λ	Wellenlänge
f	Frequenz
I	Intensität
t	Zeit
k	Wellenzahl
ω	Kreisfrequenz
c	Lichtgeschwindigkeit im Vakuum
ΔL	Weglängendifferenz
n	Realteil des Brechungsindex des Mediums
h	optischer Weg
θ	Einfallswinkel des Lichts
m	Interferenzordnung
k_0	Wellenzahl im Vakuum
φ	Phase
E	Elektrisches Feld
E_0	Amplitude des elektrischen Feldes
E_p	Elektrisches Feld der Probe
E_r	Elektrisches Feld der Referenz
φ_0	Anfangsphase
L_p	Optischer Weg in der Probe
L_r	Optischer Weg in der Referenz
S	spektrale Leistungsdichte
e	Elementarladung
η_{ph}	Quanteneffizienz des Detektors

Φ	Photonenfluss auf den Detektor
I_{dark}	Dunkelstrom des Detektors
I_{noise}	Rauschstrom des Detektors
r	Reflexionskoeffizient
a	Dämpfungskoeffizient nach Absorption
$\tilde{n}$	Komplexer Brechungsindex
κ	Imaginärteil des Brechungsindex (Absorption)
d_0	Dicke der Schicht
Φ	Phasenverschiebung
m_e	effektive Masse des Elektrons
γ	Dämpfungskoeffizient
ω_0	Eigenfrequenz
α	Polarisierbarkeit
ε	Dielektrizitätskonstante
ε_0	Elektrische Feldkonstante
$\chi(\omega)$	Elektrische Suszeptibilität
N_e	Teilchendichte
f_s	Abtastfrequenz
T_{sampl}	Abtastzeitpunkt
v_n	Rauschspannung am Widerstand
k_B	Boltzmann-Konstante
T	Temperatur
R_i	Elektrischer Widerstand
Δf	Bandbreite des Messsystems
$\mathcal{L}$	Verlustfunktion
l	Dicke des Dispersionselements
$\mathcal{F}$	kontinuierliche Fourier-Transformation

δ	Dirac-Delta-Funktion
$rect$	Rechteck-Funktion
$sinc$	kardinaler Sinus
$\bar{\omega}$	Mittelwert der Kreisfrequenz
σ	Standardabweichung der Kreisfrequenzverteilung
η	Rausch
σ_s	Streukoeffizient für Rayleigh-Streuung
R	Radius der Streupartikel
$f_{\text{back}}(\text{NA})$	Rückstreufaktor
NA	Numerische Apertur

1. Einleitung und Motivation

Für die präzise Untersuchung von Oberflächen oder der inneren Struktur von Objekten wird die Interferometrie eingesetzt [23] [13] [48]. Im Vordergrund steht dabei die Beobachtung von Interferenzerscheinungen, die im Allgemeinen entstehen, wenn zwei elektromagnetischen Wellen aufeinandertreffen (Abbildung 2.1). Zur Registrierung dieser Muster wird häufig ein Michelson-Interferometer [30] verwendet [47] [12] [11] [9] [5]; eine detaillierte Beschreibung seines Funktionsprinzips erfolgt in Abschnitt 2.1. Vereinfacht betrachtet nimmt das Interferometer (IM) Licht von einer Quelle (Q) auf und erzeugt ein Interferenzmuster (Interferogramm), das Informationen über das Objekt (P) enthält (siehe Abbildung 1.1). Um aus Interferogrammen Informationen zu gewinnen, wird eine Fourier-Transformation durchgeführt, um Spektren zu erhalten. Die Spektren liefern Informationen darüber, in welchem Maße das Licht nach der Wechselwirkung mit der Probe in seiner Intensität verändert wurde. Bei komplexen Strukturen ermöglicht die Betrachtung des Spektralbereichs, die Struktur zu rekonstruieren. Durch die Erweiterung dieses Verfahrens mittels aufeinanderfolgender Messungen an verschiedenen Punkten der Oberfläche lassen sich räumliche Scannen des Objekts erstellen. In der Praxis wird dies als optische Kohärenztomographie (OCT) bezeichnet, bei der die innere Struktur teilweise transparenter Proben mithilfe einer Breitbandquelle untersucht wird. Obwohl die Eindringtiefe von sichtbarem Licht oder Infrarotstrahlung in z.B. biologisches Gewebe typischerweise gering ist und im Durchschnitt nur wenige Millimeter beträgt [15], findet OCT breite Anwendung in der Medizin [33] [21] [37]. Mit dieser Methode lässt sich die innere Mikrostruktur verschiedener menschlicher Gewebe untersuchen, zum Beispiel von Haut [20], Blutgefäßen [43] oder der Netzhaut in Auge [50].




Abbildung 1.1: Vereinfachtes Schema des Interferometrieprozesses zur Gewinnung von Informationen über die Probe. Q – Lichtquelle, IM – Michelson-Interferometer, P – Probe, IS – interferometrisches Signal, FFT – schnelle Fourier-Transformation.

Aus mathematischer Sicht können die interferometrische Methode und die Techniken der Rekonstruktion der Eigenschaften der Probe aus dem Interferometrischen Signal, als Lösung eines inversen Problems betrachtet werden (siehe Abschnitt 2.2), wobei: Aus den gemessenen Spektren des mit dem Objekt wechselwirkenden Lichts muss die Information über das Objekt rekonstruiert werden. Während der Ausbreitung erfährt das Licht multiple Reflexionen an unterschiedlichen Strukturen innerhalb der Probe, wird gestreut, verändert die Phase der elektromagnetischen

Welle und in den Schichten teilweise absorbiert. Das registrierte interferometrisches Signal stellt die Überlagerung all dieser Beiträge dar. Die Extraktion optischer Parameter aus diesem Signal bildet die eigentliche Aufgabe der tomographischen Rekonstruktion. Da die Anzahl der zu bestimmenden Parameter sehr groß sein kann, erfordert bereits die Verarbeitung einzelner Messungen erhebliche Rechenressourcen und wird beeinträchtigt durch prinzipielle Mehrdeutigkeiten [53], optisch provozierten Einschränkungen [22] und numerischen Artefakten [52]. Insbesondere in der Medizin kommt der Rekonstruktionszeit eine zentrale Bedeutung zu. Außerdem, ein langsamer Algorithmus zur Datenverarbeitung schränkt den Einsatz der Technologie während Operationen oder routinemäßiger Untersuchungen erheblich ein. Abhilfe schaffen hier künstliche neuronale Netze, die sich in der schnellen Verarbeitung umfangreicher Datensätze bewährt haben [40] [51]. Dabei handelt es sich um mathematische Modelle, die die Funktionsweise biologischer Neuronen nachbilden und in der Lage sind, komplexe Muster in den Daten zu identifizieren. Aufgrund ihrer Generalisierungsfähigkeit [4] [7] eignen sich viele Netzarchitekturen zur effizienten Lösung inverser Probleme [17], wie sie auch in der OCT auftreten.

Die vorliegende Arbeit untersucht eine Abweichung vom etablierten Ansatz der Anwendung neuronaler Netze zur Verarbeitung von OCT-Signalen, wie beispielsweise in [8] beschrieben. Im maschinellen Lernen (Abschnitt 2.4) wird üblicherweise folgender Ablauf verfolgt: Soll ein Algorithmus zur Bildverarbeitung für bestimmte Proben, beispielsweise Haut, entwickelt werden, so wird eine einzelne interferometrische Anlage zur Erzeugung von OCT-Aufnahmen verwendet. Der Spektralbereich der Lichtquelle wird eingeschränkt, und es werden umfangreiche Datensätze durch zahlreiche Scans dieser Proben erstellt. Dieses Bildmaterial dient anschließend als Trainingsgrundlage für ein neuronales Netz, das nach dem Training in der Lage ist, die erlernten Scans zu reproduzieren. Das zentrale Problem dieses Ansatzes besteht darin, dass das Training für jeden neuen Spektralbereich stets eine separate Kalibrierungsaufgabe darstellt. Selbst innerhalb eines Bereichs ist die Anwendbarkeit des Netzes eingeschränkt. Ein trainiertes Modell ist ausschließlich für Daten geeignet, die mit einer spezifischen interferometrischen Konfiguration gewonnen wurden. Wird hingegen ein OCT-Aufbau mit veränderten Parametern optischer Komponenten (z.B. einer anderen Detektorauflösung) eingesetzt, so lassen sich die Daten desselben Bereichs nicht zuverlässig rekonstruieren. Auch in diesem Fall ist eine erneute Kalibrierung des Modells erforderlich.

Das Ziel der Arbeit besteht daher darin, den Trainingsprozess so zu modifizieren, dass die Parameter des verwendeten OCT-Aufbaus von Beginn an berücksichtigt werden. Das Training eines neuronalen Netzes stellt an sich einen statistischen Prozess dar. Dabei stützt sich das Netz während der Berechnungen nicht direkt auf physikalische Gesetze. Der Prozess der Erzeugung und Messung interferometrischer Signale kann hingegen durch physikalische Gesetzmäßigkeiten beschrieben werden. Die Physik erlaubt es, mit der erforderlichen Genauigkeit vorherzusagen, wie die Abhängigkeit bei gegebenen Parametern aussehen wird – ein deterministischer Ansatz. Sind die Parameter des OCT-Systems und der Probe bekannt, kann das entsprechende Spektrum auf Grundlage der physikalischen Gesetze simuliert werden. Die Genauigkeit der Simulation wird

dabei allein anhand der Vollständigkeit der Beschreibung der physikalischen Modells bestimmt. Die Integration dieses deterministischen Ansatzes in den statistischen Lernprozess führt zu einer zusätzlichen Abhängigkeit von den physikalischen Parametern. Im weiteren Verlauf der Arbeit wird die Umsetzung eines solchen hybriden Ansatzes anhand eines CycleGAN (Abschnitt 2.4), einer speziellen Architektur generativer adversarieller Netzwerke, beschrieben. Diese Architektur (Abbildung 2.20) stellt vereinfacht einen Zyklus zwischen zwei unterschiedlichen Datensätzen dar, wobei die neuronalen Netze zwischen ihnen die Transformation eines Datensatzes in den anderen übernehmen. Schematisch entspricht dies der Lösung eines inversen Problems [54]. Eine der Transformationen wurde dabei durch einen deterministischen Algorithmus ersetzt. Als Ergebnis wurde ein Netzwerk entwickelt, welches den Wert des Parameters der optischen Wegdifferenz Δ (vgl. Abschnitt 2.1) auf Basis des Spektrums vorhersagen kann und sich zugleich flexibel an unterschiedliche Aufbauten der verwendeten OCT-Systeme anpassen lässt. Am Ende wird ein CycleGAN-Ansatz betrachtet, diesmal jedoch ohne deterministischen Ansatz, für eine komplexere Aufgabe – die Analyse von B-Scans (Abschnitt 2.1.3) in der OCT. Zur Datengenerierung wird hierbei externer, bereits vorhandener Algorithmus [35] zur Erstellung realistischer OCT-Scans schichtartiger Strukturen eingesetzt.

2.Theoretische Grundlagen

2.1 Grundlagen der Weißlichtinterferometrie

Die Grundlage der Weißlichtinterferometrie ist das Phänomen der elektromagnetischen Welleninterferenz - die Überlagerung einer elektromagnetischen Welle durch eine andere[6]. Abhängig davon, wie die beiden Wellen miteinander korreliert sind, können zwei Situationen auftreten: Entweder verstärken sich die Wellen gegenseitig, oder die erste löscht die zweite aus. Die Korrelation bzw. Kohärenz der Wellen wird durch die optische Wegdifferenz bestimmt – dem Unterschied der zurückgelegten Weglängen der Wellen bis zur Interferenz. Diese optische Wegdifferenz führt zu einer Phasendifferenz zwischen den Wellen, welche direkt das Interferenzmuster beeinflusst. Die Phasendifferenz $\Delta\varphi$ lässt sich durch die Formel beschreiben.

$$\Delta\varphi = \frac{\omega}{c} \cdot \Delta L \quad (2.1)$$

wobei ω die Wellenfrequenz, c die Lichtgeschwindigkeit und ΔL die optische Wegdifferenz ist.

Ein stabiles Interferenzmuster wird nur beibehalten, wenn die Differenz der optischen Wege kleiner ist als die Kohärenzlänge der Quelle. Dies ist ein Quellenmerkmal, das der maximalen optischen Wegdifferenz entspricht, bei der die Lichtwellen ihr festes Phasenverhältnis beibehalten können. Eine klassische und eine der einfachsten Demonstrationen der Lichtinterferenz ist das Experiment von Young (Abbildung 2.1)[49].




Abbildung 2.1: Schematische Darstellung des Youngschen Doppelspaltexperiment zur Demonstration der Welleninterferenz. LQ – monochromatische Lichtquelle, DS – Doppelspalte, S – Beobachtungsschirm, IB – Interferenzbild

Monochromatisches Licht fällt auf einen Doppelspalt und erzeugt von jedem Spalt ausgehende Wellen, die kohärent zueinander sind. Diese Kohärenz entsteht, weil das Licht zu beiden Spalten denselben Weg zurücklegt und die Phasendifferenz konstant bleibt. Die beiden Wellen überlagern sich auf dem Schirm und bilden ein Interferenzmuster aus hellen und dunklen Streifen, dessen Intensität von der optischen Wegdifferenz zu jedem Punkt auf dem Schirm abhängt.

Wenn eine der Wellen zuvor von der Oberfläche einer Probe reflektiert wurde, ermöglicht

die Analyse des resultierenden Interferenzmusters nützliche Erkenntnisse. Bei vollständiger Reflexion der Welle an der Oberfläche kann der Abstand zum Objekt durch die Analyse der Periodizität der Interferenzmaxima bestimmt werden, welche mit dem Unterschied der optischen Weglängen zwischen den reflektierten Wellen(ΔL) zusammenhängt.

Wenn ein Material für Licht transparent ist, trägt die aus seiner Tiefe austretende Welle Informationen über die Struktur und kann bereits Interferenzen verursachen. In der Näherung der geometrischen Optik trifft ein Strahl aus einer monochromatischen Quelle mit Frequenz ω unter einem Winkel θ auf die Oberfläche einer dünnen Schicht (Abbildung 2.2). Eine dünne Schicht ist eine durchgehende Materialschicht auf einem Substrat, deren Dicke deutlich kleiner ist als ihre lateralen Abmessungen und vergleichbar mit der Wellenlänge des verwendeten Lichts. Um die Phasenverschiebung bei der Reflexion auszugleichen, wurde der Brechungsindex des Substrats n_3 größer gewählt als der Brechungsindex der Schicht n_2 .




Abbildung 2.2: Interferenz eines Strahls an einer dünnen Schicht. LQ – monochromatische Lichtquelle, SC – dünne Schicht, S – Schirm, S_1 – erster Strahl, S_2 – zweiter Strahl. ω – Kreisfrequenz der Quelle, n_1 – Brechungsindex der Luft, n_2 – Brechungsindex der Schicht, n_3 – Brechungsindex des Substrats, h – Dicke der Schicht, θ – Ausbreitungswinkel in der Schicht

Beim Auftreffen wird der Strahl in zwei Komponenten aufgeteilt S_1 und S_2 . Ein Strahl S_1 wird teilweise an der Oberfläche reflektiert, während der andere Strahl S_2 in das Material eindringt. Nach dem Snellius-Gesetz [18] ändert der durchdringende Strahl seine Richtung, da die Ausbreitungsgeschwindigkeit vom Brechungsindex n abhängt. Nach der Reflexion an der Grenzfläche des Films breitet sich der Strahl zur Oberfläche aus, wo er erneut gebrochen wird. Somit weisen die beiden Strahlen, die sich von der Filmoberfläche aus ausbreiten, eine optische Wegdifferenz auf. Durch Überlagerung der beiden Strahlen mit einer Linse lassen sich Maxima oder Minima der Lichtintensität, also ein Interferenzbild, beobachten. Die Gleichung, die die entstehende Interferenz beschreibt, lautet wie folgt:

$$n_1 h \cos \theta = m \frac{\omega}{\pi c}, \quad m \in \mathbb{Z} \quad (2.2)$$

wobei m die Interferenzordnung ist.

Die Untersuchung der genannten Interferenzfälle einer Probe erfolgt bequem mit Hilfe eines speziellen Messgeräts, dem Interferometer. Im Wesentlichen besteht jeder Interferometer aus

folgenden Teilen: einer Strahlungsquelle, einem Strahlteiler, Komponenten der Phasenänderung der Welle sowie einem Detektor. Eine der weit verbreiteten Varianten stellt das Michelson-Interferometer[30] dar (siehe Abbildung 2.3).




Abbildung 2.3: Schema des Michelson-Interferometers: L – Lichtquelle, ST – Strahlteiler, R – Referenzspiegel, P – Probe, IS – Interferenzsignal, SM – Spektrometer. L_r und L_p bezeichnen die Armlängen des Interferometers. E steht für das Quellfeld, während E_r und E_p die elektrischen Felder in den beiden Armen darstellen.

Zur weiteren Darstellung des Funktionsprinzips des Interferometers werden einige Vereinfachungen des physikalischen Modells angenommen. Dies betrifft insbesondere die Verteilung des elektrischen Feldes:

- Eine homogene ebene Welle – die Wellenfronten stellen die Ebenen einer konstanten Phase dar.

$$k_0 \cdot z = \varphi \quad (2.3)$$

wobei k_0 die Wellenzahl ist, die die räumliche Periodizität der Welle beschreibt, und z die Ausbreitungsrichtung entlang der Raumachse bezeichnet.

- Skalare Näherung – die Welle hat keine Polarisation.

$$E_0 \in \mathbb{R} \quad (2.4)$$

wobei E_0 der Amplitude des elektrischen Feldes ist.

- Nur die elektrische Komponente des elektromagnetischen Feldes.

Basierend auf den oben genannten Annahmen lässt sich die allgemeine Lösung der Helmholtz-Gleichung für eine ebene Welle formulieren, die sich in einem homogenen Raum ausbreitet[29]:

$$E(z) = E_0 e^{ik_0 z} \quad (2.5)$$

wobei $E(z)$ das elektrische Feld als Funktion des Ortes beschreibt, E_0 die reelle Amplitude ist und der Ausdruck e^{ik_0z} die komplexe Darstellung der Phasenabhängigkeit in Raumrichtung z angibt.

Die Spannung am Detektor E_{det} resultiert aus der Überlagerung der beiden reflektierten Wellen E_p und E_r (Abbildung 2.1).

$$E_{det} = E_p + E_r = \frac{E_0}{\sqrt{2}} e^{i\varphi_0} \left(e^{i2k_0L_p} + e^{i2k_0L_r} \right) = \frac{2E_0}{\sqrt{2}} e^{i\varphi_0} e^{ik_0(L_p+L_r)} \cos(k_0(L_r - L_p)) \quad (2.6)$$

Die Intensität einer elektromagnetischen Welle beschreibt die mittlere Energieflussdichte pro Fläche und Zeit, die senkrecht zur Ausbreitungsrichtung der Welle transportiert wird.

$$I \propto E_{det} \cdot E_{det}^* = 2E_0^2 \cos^2(k_0(L_r - L_p)) = 2E_0^2 \cos^2(\Delta\varphi) \quad (2.7)$$

wobei $\Delta\varphi$ die Phasendifferenz aus Formel 2.1 ist.

Zurückgehend auf die Struktur des Michelson-Interferometers weist dieses einen Vorteil auf. Im Young'schen Versuch (Abbildung 2.1) ist die Verwendung nichtmonochromatischen Lichts hingegen problematisch, da die Interferenzmuster für verschiedene Wellenlängen unterschiedliche Interferenzstreifenabstände besitzen, sich überlagern und sich gegenseitig ausmitteln, wodurch das sichtbare Muster aus Maxima und Minima verschwindet. Im Fall eines Interferometers ist die Verwendung einer nichtmonochromatischen Lichtquelle möglich, da die optische Wegdifferenz der Strahlen durch verschiebbare Arme mit Referenzspiegel(R) oder Probe(P) präzise kontrolliert werden kann (Abbildung 2.2). Da die Wellenlängen der elektromagnetischen Strahlung in der Interferometrie typischerweise im Mikrometerbereich liegen, wird die optische Wegdifferenz meist innerhalb der Kohärenzlänge der Quelle eingestellt. Obwohl die optische Wegdifferenz auch größer sein kann, muss sie für die Entstehung eines stabilen Interferenzmusters nahe einem ganzzahligen Vielfachen der Wellenlänge liegen. Die hauptsächliche Einschränkung ergibt sich aus der Kohärenzlänge und der Leistung der Quelle. Eine wichtige Klarstellung ist, dass die verwendete Wellenlänge viel kleiner ist als der Abstand zwischen dem Teiler und den Armen ($L_r = L_p \gg \lambda$).

Dabei wird häufig eine breitbandige, sogenannte Weißlichtquelle verwendet, deren kurze Kohärenzlänge haben. Wenn die untersuchte Probenoberfläche das Licht nicht vollständig reflektiert, kann mit einer Quelle kurzer Kohärenzlänge in das Material eingedrungen werden. Das Interferenzmuster wird so zum Abbild der reflektierenden Schichten im untersuchten Material. Somit ermöglicht eine Weißlichtquelle eine hohe räumliche Auflösung in der Tiefenrichtung. Abhängig von der Konfiguration des Detektionssystems im Michelson-Interferometer kann das Interferenzsignal auf zwei Arten untersucht werden:

2.1.1 Zeitbereich-Weißlichtinterferometrie




Abbildung 2.4: Schema der Michelson-Interferometer-Konfiguration für Untersuchungen im Zeitbereich. ST – Strahlteiler, R – Referenzspiegel, P – Probe, IS – Interferenzsignal, D – Detektor. L_r und L_p bezeichnen die Armlängen des Interferometers. ΔL_r bezeichnet eine Änderung der Schulterlänge

Gegenstand der Untersuchung ist das integrale Interferenzsignal, das durch die Überlagerung der Strahlung im gesamten Spektralbereich der Quelle entsteht. Durch die mechanische Veränderung der optischen Weglänge in einem der Arme des Interferometers (R oder P) wird die zeitliche Veränderung des Interferenzmusters registriert. Unter Verwendung der Formel 2.7 kann die Intensität wie folgt ausgedrückt werden:

$$I(t) = \int_0^{\infty} 2S(\omega) \cos^2(\omega t) d\omega \quad (2.8)$$

wobei $S(\omega)$ die Verteilung der Lichtleistung der Quelle (spektrale Leistungsdichte) über die Frequenzen und $t = \frac{L_r - L_p}{c}$ die zeitliche Verzögerung zwischen den beiden Interferenzarmen ist.

Anstelle eines Spektrometers wird ein Matrix-Detektor (D) eingesetzt, der für jedes Pixel die Gesamtintensität erfasst. In der Weißlichtinterferometrie werden in der Regel Detektoren auf Basis von CCD (Charge-Coupled Device) eingesetzt. Solche Detektoren (Abbildung 2.5) bestehen aus einer lichtempfindlichen Halbleiterstruktur, die eine elektrische Ladung sammelt, welche proportional zur Anzahl der einfallenden Photonen ist [24].




Abbildung 2.5: Schematische Darstellung einer einzelnen, vereinfachten CCD-Zelle. S — Steuerelektrode, D — dielektrische Schicht, PT — Potentialtopf

Trifft ein Photon auf die transparente Streuer-Elektrode(S), durchdringt es die darüberliegende Oxidschicht(DS) und wird im Halbleitersubstrat absorbiert. Durch die angelegte positive Bias-Spannung bildet sich unterhalb der Elektrode eine Verarmungszone sowie ein Potentialtopf(PT), in dem die durch die Photoabsorption generierten Elektronen-Loch-Paaren eingefangen werden. Voraussetzung für diesen Prozess ist, dass die Energie des Photons größer ist als die Bandlücke (Bandgap) des Halbleitersmaterials. Der in der Zelle entstehende Strom kann durch folgende Gleichung beschrieben werden:

$$I_{\text{CCD}} = (e \cdot \eta_{ph} \cdot \Phi) + I_{\text{dark}} + I_{\text{noise}} \quad (2.9)$$

wobei e die Elementarladung des Elektrons darstellt, η_{ph} die Quantenwirkungsgrad ist, der den Anteil der Photonen angibt, der Ladungsträger in der Verarmungszone erzeugt, und Φ den Photonenfluss pro Sekunde beschreibt, der in die Potentialtopf(PT) gelangt.

Der erste Teil der Formel 2.9 beschreibt den Fotostrom, der durch die Erzeugung von Elektron-Loch-Paaren unter Lichteinwirkung entsteht. Der zweite Teil, I_{dark} , stellt den Generations-Rekombinations-Strom in der p-n-Diode dar, der auch ohne Licht vorhanden ist. Sein Wert hängt vom Material ab, erfordert die Anpassung empirischer Koeffizienten und zeigt eine starke Temperaturabhängigkeit. Der letzte Teil, I_{noise} , resultiert aus den zufälligen Rauschanteilen, die jeder Zellkomponente eigen sind und zum Gesamtstrom beitragen.

2.1.2 Fourierbereich-Weißlichtinterferometrie




Abbildung 2.6: Schema der Michelson-Interferometer-Konfiguration für Untersuchungen im Fourierbereich. R – Referenzspiegel, P – Probe, ST – Strahlteiler, IS – Interferenzsignal, SM – Spektrometer, K – Kollimatorsystem, D – Detektor, G – Beugungsgitter. L_r und L_p bezeichnen die Armlängen des Interferometers

Im Gegensatz zum Zeitbereich erfolgt hier die Untersuchung jeder spektralen Komponente des Interferenzsignals einzeln. Die Arme mit der Probe (P) und dem Spiegel (R) sind fixiert und werden während der Analyse nicht verändert (Abbildung 2.6). Das Interferenzsignal gelangt über den kollimierenden Eingang (K) in das Spektrometer. Der Spalt am Eingang formt zunächst das Strahlprofil im Spektrometer und bestimmt die Auflösung. Anschließend durchläuft der Strahl eine Linse im Kollimatorsystem, die den divergenten Strahl vom Spalt in einen parallelen Strahl umwandelt. Danach treffen Strahlen unterschiedlicher Frequenzen unter demselben Winkel auf das Beugungsgitter (G). Unterschiedliche Frequenzen werden unter verschiedenen Winkeln gebeugt und fallen anschließend auf jeweils einzelne Pixel des Matrixdetektors. Auf dem Detektor (D) wird somit die Abhängigkeit der Intensität der einfallenden Strahlung von der Wellenlänge $I(\lambda)$ des einfallenden Lichts registriert.




Abbildung 2.7: Beispiel eines simulierten typischen Interferogramms in der Weißlichtinterferometrie, erfasst am Detektor

Das aufgezeichnete Interferogramm enthält Informationen über die Probe. Besitzt die Probe

eine geschichtete interne Struktur, so interagiert das einfallende Weißlicht unterschiedlich mit Streuern und Reflektoren. Als Streuer kommen beispielsweise Defekte in der Kristallstruktur oder Partikel anderer Materialien innerhalb der Probe in Frage. Reflektoren sind in der Regel interne Oberflächen. Das Interferogramm stellt somit im Wesentlichen eine Superposition der Signale aller reflektierenden und streuenden Strukturen dar. Das vereinfachte Modell, basierend auf den in den Gleichungen 2.3, 2.4 und 2.5 eingeführten Vereinfachungen, zur Beschreibung des Interferenzsignals von einer solchen geschichteten Probe, sieht wie folgt aus:

$$E_{IS}(\omega) = E_R(\omega) + E_{P,0}(\omega) + \sum_{m=1}^N E_{P,m}(\omega) \quad (2.10)$$

wobei $E_{IS}(\omega)$ das gesamte interferometrische Signal ist, $E_R(\omega)$ das Referenzsignal, $E_{P,0}(\omega)$ das direkt von der Probenoberfläche reflektierte Feld und $E_{P,m}(\omega)$ das von der m -ten Schicht innerhalb der Probe reflektierte Feld.

Das vom Referenzspiegel reflektierte Feld E_R wird so angenommen, dass es sich bei der Ausbreitung in der Luft zwischen den Interferometerarmen nicht verändert. Für die Probe hingegen muss nicht nur die Reflexion innerhalb des Materials $E_{P,m}(\omega)$, sondern auch die an der Grenzfläche der ersten Oberfläche $E_{P,0}(\omega)$ berücksichtigt werden.




Abbildung 2.8: Die Reflexion einer elektromagnetischen Welle E an einer geschichteten Probe mit $(m+1)$ Schichten. ST – Strahlteiler, P – Probe. d_0 ist der Abstand vom ST bis zur Oberfläche der Probe(P), während d mit dem Index m die Schichtdicken beschreibt. Die Parameter, die eine Schicht charakterisieren, sind: a – Dämpfungskoeffizient nach Absorption, r – Reflexionskoeffizient(Fresnel-Koeffizient), k – Wellenvektor des Mediums, sowie ϕ – die Phasenänderung bei der Reflexion.

Zur Beschreibung des Feldes, das verschiedene Schichten durchläuft, müssen Größen eingeführt werden, die deren Parameter charakterisieren.

$$k = \frac{2\pi n_m}{\lambda} \quad (2.11)$$

$$r = \frac{n_m - n_{m+1}}{n_m + n_{m+1}} \quad (2.12)$$

$$a = e^{(-\kappa_m d_m)} \quad (2.13)$$

wobei n_m der Brechungsindex der m -ten Schicht ist und κ_m den Extinktionskoeffizienten der m -ten Schicht bezeichnet. Diese Parameter sind durch die komplexe Brechungszahl $\tilde{n}_m = n_m + i\kappa_m$ verbunden.

Der erste Parameter $E_{P,0}$ (Formel 2.10) des Feldes, das mit der Probe wechselwirkte, entspricht der Reflexion an der Oberfläche.

$$E_{P,0}(\omega) = E(\omega) r_0(\omega) \exp \left[i(2k_0(\omega)d_0 + \varphi_0(\omega)) \right] \quad (2.14)$$

wobei $E(\omega)$ die spektrale Amplitude der einfallenden Welle bezeichnet, $r_0(\omega)$ der Reflexionskoeffizient an der ersten Grenzfläche ist, $k_0(\omega)$ die Wellenzahl im Medium zwischen den Armen des Interferometers, d_0 die optische Weglänge zwischen ST und P, $\varphi_0(\omega)$ die phasenabhängige Verschiebung bei der Reflexion an der Oberfläche beschreibt.

Da die Welle an der Oberfläche reflektiert wird und keine Dämpfung erfährt, erfolgt die Änderung der Amplitude nur durch den Fresnel-Koeffizienten $r_0(\omega)$. In der Phase ist der doppelte Weg bis zur Oberfläche und zurück zum Strahlteiler sowie die Phasenverzögerung bei der Reflexion berücksichtigt.

Bevor die Beschreibung eines Feldes $E_{P,m}(\omega)$ nach Durchlaufen von $(m+1)$ Schichten erfolgt, werden einige vereinfachende Annahmen getroffen. Analog zur Welle bei der Beschreibung eines Michelson-Interferometers wird die Polarisierung vernachlässigt (Formel 2.4). Mehrfache Reflexionen innerhalb der Schichten werden nicht berücksichtigt; es wird nur eine Reflexion an jeder Materialgrenze angenommen. Zufällige Phasenfluktuationen sowie Streuungen an Defekten der inneren Struktur werden ebenfalls ausgeschlossen. Alle genannten Effekte beeinflussen zwar die Entstehung des Interferenzbildes, sind jedoch in typischen biologischen Proben, auf die der Fokus dieser Arbeit gelegt wird, kaum wahrnehmbar[25]. Die folgende Beschreibung stellt daher eine idealisierte und vereinfachte Darstellung dar, die sich für einfache Computersimulationen eignet.

$$\begin{aligned} E_{P,m+1}(\omega) = E(\omega) & \left[\prod_{j=1}^{m-1} a_j^2(\omega) \right] a_m^2(\omega) \\ & \cdot r_{m+1}(\omega) \left[\prod_{j=1}^{m-1} (1 - r_m(\omega)) \right] \\ & \cdot \exp \left[i \Phi_m(\omega) \right], \quad m = 1, \dots, N \end{aligned} \quad (2.15)$$

wobei $a_j(\omega)$ die Amplituden-Transmissionskoeffizienten der Schichten darstellen, $r_m(\omega)$ der Reflexionskoeffizient an der m -ten Grenzfläche ist und $\Phi_m(\omega)$ die akkumulierte Phasenver-

schiebung beim Durchlaufen der Schichten beschreibt.

Die Formel 2.15 berücksichtigt sowohl die Abschwächung der Amplitude durch den aktuellen Schichtdurchgang a_m , als auch die Beiträge der zuvor durchlaufenen Schichten $\left(\prod_{j=1}^{m-1} a_j^2(\omega)\right)$. Die Quadrate der Koeffizienten a_m und a_j entstehen aufgrund des Hin- und Rückgangs der Welle. Zusätzlich wird die Amplitudenänderung durch den Reflexionskoeffizienten an den Grenzflächen r_m beeinflusst. Die Phasenänderung $\Phi_m(\omega)$ während der Ausbreitung durch die Schichten setzt sich ebenfalls aus mehreren Termen zusammen.

$$\Phi_m(\omega) = 2k_0(\omega)r_0 + \varphi_0(\omega) + 2 \sum_{j=1}^m k_j(\omega)d_j + \sum_{j=1}^m \varphi_j(\omega) \quad (2.16)$$

wobei $k_j(\omega)$ die Wellenzahl in der Schicht ist, d_j die Dicke der jeweiligen Schicht und $\varphi_j(\omega)$ die phasenabhängige Verschiebung an der Grenzfläche der Schicht beschreibt.

Der erste Term $(2k_0(\omega)r_0)$ beschreibt die Phasenverschiebung, die durch das Medium außerhalb der Probe verursacht wird, welches die Welle bis zur Probenoberfläche durchläuft und nach der Reflexion in der Tiefe der Probe bis zum Strahlteiler ST zurückkehrt. Der zweite Term entspricht der Reflexion an der Probenoberfläche $\phi_0(\omega)$. Der dritte und vierte Term charakterisieren die Phasenänderung in Abhängigkeit von der Wellenzahl $k_j(\omega)$ und der Weglänge d_j in der Schichten sowie die entsprechende Phasenverschiebung an den Schichtgrenzen φ_j .

Da der Wellenvektor $k_j\omega$ in diesem Fall von der Frequenz abhängt, muss die Dispersion im Medium für elektromagnetische Wellen genauer betrachtet werden. Hierfür wird die klassische Lorentz-Theorie herangezogen, die das Verhalten des Brechungsindex eines Materials in Abhängigkeit von der Feldfrequenz beschreibt. Sie basiert auf den folgenden physikalischen Annahmen[27]:

- Elektronen innerhalb einer Substanz sind an die Atomkerne gebunden und verhalten sich wie harmonisch schwingende Teilchen.
- Ein elektromagnetisches Wechselfeld regt diese Elektronen zu Schwingungen an.
- Im System ist eine intrinsische Dämpfung vorhanden, die Streu- sowie Absorptionsverluste zur Folge hat.

Aus den oben genannten Annahmen ergibt sich, dass der Bewegungsablauf eines Elektrons durch eine Differentialgleichung zweiter Ordnung modelliert werden kann[19].

$$m_e \frac{d^2 z(t)}{dt^2} + m_e \gamma \frac{dz(t)}{dt} + m_e \omega_0^2 z(t) = -eE(z, t) \quad (2.17)$$

dabei ist $z(t)$ die Auslenkung des Elektrons aus der Gleichgewichtslage, γ der Dämpfungskoeffizient, m_e die effektive Masse des Elektrons, ω_0 die Eigenfrequenz (Resonanzfrequenz) des

Oszillators, e die Elementarladung des Elektrons und $E(z, \omega) = E_0 e^{i(k_0 z - \omega t)}$ das elektrische Feld der Lichtwelle.

Die stationäre Lösung dieser Differentialgleichung beschreibt die Amplitude der Schwingungen des Elektrons unter dem Einfluss einer elektromagnetischen Welle.

$$z(\omega) = -\frac{e}{m_e} \cdot \frac{E(z)}{\omega_0^2 - \omega^2 - i\gamma\omega} \quad (2.18)$$

Der induzierte Dipolmoment ist dann gegeben durch $-ex(z, t)$ und die polarisierbare Antwort des Mediums wird durch die komplexe Polarisierbarkeit beschrieben:

$$\alpha(\omega) = \frac{e^2}{\varepsilon_0 m_e} \cdot \frac{1}{\omega_0^2 - \omega^2 - i\gamma\omega} \quad (2.19)$$

Die Polarisation und das elektrische Feld sind über die frequenzabhängige Suszeptibilität $\chi(\omega)$ miteinander verknüpft:

$$P(\omega) = \varepsilon_0 \chi(\omega) E \quad (2.20)$$

wobei ε_0 die elektrische Feldkonstante (Permittivität des Vakuums) ist.

Betrachtet man das Material als eine Summe solcher Dipole, so lässt sich die komplexe dielektrische Permittivität bestimmen.

$$\varepsilon(\omega) = \varepsilon_0 [1 + \chi(\omega)] = \varepsilon_0 + \frac{Ne^2}{m_e(\omega_0^2 - \omega^2 - i\gamma\omega)} \quad (2.21)$$

wobei N die Elektronendichte ist.

Ausgehend von der Definition des komplexen Brechungsindex ergibt sich folgende Gleichung:

$$\tilde{n}(\omega) = n + i\kappa = \sqrt{\frac{\varepsilon(\omega)}{\varepsilon_0}} = \sqrt{1 + \frac{Ne^2}{m_e(\omega_0^2 - \omega^2 - i\gamma\omega)}} \quad (2.22)$$

Somit kann der Brechungsindex durch die Resonanzfrequenzen der Elektronen in den Atomen des Materials beschrieben werden. In der Praxis ist die Bestimmung aller erforderlichen theoretischen Parameter jedoch mit erheblichen Schwierigkeiten verbunden. In realen Materialien treten zahlreiche überlappende Resonanzen auf[31]. Dies erschwert die Interpretation experimenteller Daten. Eine direkte Ableitung der Daten aus der wellenlängenabhängigen Brechungszahl ist daher nicht möglich. Daher sind indirekte Messmethoden erforderlich, beispielsweise spektroskopische Verfahren wie NMR oder IR-Resonanz, um den Extinktionskoeffizienten sowie die Resonanzfrequenzen zu ermitteln.




Abbildung 2.9: Abhängigkeit der Komponenten des Brechungsindex von der Anregungsfrequenz ($e = 1,602 \times 10^{-19}$ C, $m = 9,109 \times 10^{-31}$ kg, $\varepsilon_0 = 8,854 \times 10^{-12}$ F/m, $f_0 = 1,5 \times 10^{15}$ Hz, $\gamma_f = 1 \times 10^{14}$ Hz)

Für praktische Berechnungen erweist sich die Sellmeier-Gleichung[38] als besonders zweckmäßig, wobei bestimmte Annahmen getroffen werden müssen. Es werden Frequenzbereiche betrachtet, die nicht in der Nähe elektronischer Resonanzen liegen ($\omega < \omega_0$). In diesen Bereichen kann die Absorption vernachlässigt werden ($\gamma \approx 0$). Da der Brechungsindex üblicherweise in Abhängigkeit von der Wellenlänge angegeben wird, erfolgt der Übergang zur Wellenlängendarstellung zwecks Vereinfachung der weiteren Berechnungen.

$$\tilde{n}(\omega) = \sqrt{1 + \frac{N_e^2}{\varepsilon_0 m_e} \cdot \frac{\lambda^2}{\omega_0^2 \lambda^2 - (2\pi c)^2}} = \sqrt{1 + \frac{B\lambda^2}{\lambda^2 - C}} \quad (2.23)$$

wobei $B = \frac{N_e^2}{\varepsilon_0 m_e}$ und $C = \frac{(2\pi c)^2}{\omega_0^2}$.

Für Materialien mit einer großen Anzahl von Resonanzfrequenzen wird die Gleichung um eine Summenreihe mit entsprechenden Koeffizienten erweitert.

$$\tilde{n}(\lambda) = \sqrt{1 + \sum_j \frac{B_j \lambda^2}{\lambda^2 - C_j}} \quad (2.24)$$

Die Dispersion in der Probe verwischt das Interferogramm, da unterschiedliche Frequenzkomponenten der Lichtquelle beim Durchlaufen der Probe verschiedene optische Laufzeiten erfahren. Dies führt zu einer Streckung des Pulses und einer Verringerung der Tiefenauflösung. In der Methode der «dispersion-compensation-OCT»[46] wird zur Kompensation dieses Effekts ein zusätzliches Dispersions-Element in einen der Arme des Interferometers eingefügt. Das Dispersions-Element wird so ausgewählt, dass die kombinierte Dispersion von Probe und Kompensations-Element minimiert wird.




Abbildung 2.10: Schema des Michelson-Interferometers mit einem Dispersionselement in Referenzarm. R – Referenzspiegel, P – Probe, ST – Strahlteiler, IS – Interferenzsignal, SM – Spektrometer. L_r und L_p bezeichnen die Armlängen des Interferometers. n ist der Brechungsindex des Dispersionselements und L_n dessen Länge

Nachdem die Einflüsse auf das Interferogramm in Abbildung 2.7 detailliert beschrieben wurden, können nun betrachtet werden, wie aus diesem Interferogramm Informationen über die Probe gewonnen werden. Im Idealfall stellt das Interferogramm eine Superposition von Kosinusfunktionen mit unterschiedlichen Frequenzen dar, wobei die Frequenz der Kosinusfunktion proportional zur Tiefe des Reflektors ist. In realen Proben ist dies jedoch nicht der Fall, und der ideale Kosinus wird durch die Auflösung des Detektors, die Dispersion sowie die Rauschanteile des Messsystems verfälscht. Dadurch ergibt sich eine Superposition komplexer oszillierender Funktionen. Jede dieser Komponenten entspricht ihrer eigenen optischen Tiefe der reflektierenden Schicht $k_j d_j$ (Formel 2.16) in der Probe. Um diese Information zugänglich zu machen, wird die Fourier-Transformation angewendet. Sie überführt das Signal aus dem Frequenzraum in den Tiefenraum.

$$F(\omega) = \int_{-\infty}^{\infty} I(\lambda) e^{-i\omega\lambda} d\lambda = A(\omega) e^{i\varphi(\omega)} \quad (2.25)$$

wobei $F(\omega)$ das komplexe Ergebnis der Fourier-Transformation ist, $A(\omega)$ die Amplitude des Spektrums beschreibt und $\varphi(\omega)$ die Phase angibt.

Aufgrund der Eigenschaften der Fourier-Transformation ergibt sich für das Signal ein symmetrisches Spektrum, da positive und negative Frequenzen denselben Beitrag liefern (komplex-konjugierte Symmetrie). Der Betrag des komplexen Spektrums definiert die Amplitude und enthält die wesentlichen Informationen über die Intensität des reflektierten Lichts bei verschiedenen Frequenzen. In der Weißlichtinterferometrie spiegelt die Amplitude (Formel 2.26) die Stärke der Signale wider, die durch Reflexion und Streuung in der untersuchten Probe entstehen. Sie ermöglicht die Unterscheidung von Schichten der Probe und die Beurteilung ihrer optischen Eigenschaften. Außerdem kann die Amplitude zur Erstellung von Tiefenprofilen der Reflexionen verwendet werden.

$$A(\omega) = |F(\omega)| = \sqrt{\text{Re}[F(\omega)]^2 + \text{Im}[F(\omega)]^2} \quad (2.26)$$

Die Phase (Formel 2.27) wird durch das Verhältnis von Imaginär- und Realteil des Spektrums

bestimmt und gibt die Phasenverschiebungen der einzelnen Harmonischen wieder.

$$\varphi(\omega) = \arg(F(\omega)) = \arctan\left(\frac{\text{Im}[F(\omega)]}{\text{Re}[F(\omega)]}\right) \quad (2.27)$$

Die Peaks im Betrag des Fourier-Transforms des Interferogramms charakterisieren die Position der reflektierenden Oberflächen innerhalb der Probe (Abbildung 2.11). Ihre Lage entspricht der optischen Tiefe der jeweiligen Schichten, während die Amplitude der Peaks die Stärke der Reflexionen wiedergibt. Das Vorhandensein des Spiegelbildes im negativen Frequenzbereich halbiert ebenfalls die nutzbare Information. Aufgrund der Einschränkung des Nyquist-Shannon-Theorems (Formel 2.32) wird nur der positive Teil der Daten mit der Anzahl von $(N/2)$ Punkten betrachtet, wobei N die ursprüngliche Anzahl der Punkte vor der Fourier-Transformation darstellt.




Abbildung 2.11: Beispiel der Fourier-Transformation des Interferogramms einer typischen mehrschichtigen Probe. Die Abbildung zeigt nur die Amplitude des Fourier-Spektrums

2.1.3 Optische kohärente Tomographie




Abbildung 2.12: Visualisierung der drei Scan-Typen in der OCT. A-Scan – Eindimensionales Tiefenscanning entlang der z-Achse. B-Scan – Zweidimensionales Bild, erzeugt durch Aufeinanderfolge von A-Scans entlang der x-Achse. C-Scan – Dreidimensionales Volumenscanning, erweitert die B-Scans durch zusätzliche Bewegung entlang der y-Achse. P – Größe des Objekts entlang der x-Achse, Q – Größe des Objekts entlang der y-Achse, N – Scan-Schritt.[42]

Die Tomographie ist eine Methode zur Untersuchung der inneren Struktur von Proben, bei der Querschnitte der Probe auf der Grundlage von Messungen der Verteilung physikalischer Größen (z. B. Absorption, Streuung, Brechung oder Dichte) entlang verschiedener Richtungen berechnet werden. Eine Form der Tomographie, die auf der zuvor beschriebenen Methode der Weißlichtinterferometrie (Abschnitt 2.1) basiert, wird als optische Kohärenztomographie (OCT) bezeichnet. Dabei wird niedrigkohärentes Licht verwendet, um hochauflösende Bilder der inneren Schichten der Probe zu erzeugen, wodurch Strukturen mit mikrometrischer Auflösung visualisiert werden können[2]. Sie ist zudem ein nichtinvasives und nichtdestruktives Verfahren, was insbesondere bei der Untersuchung biologischer Gewebe in der Medizin von Bedeutung ist. In Abbildung 2.12 wird gezeigt, wie im Rahmen der OCT die Anwendung der Spektrumerfassung aus dem registrierten Interferogramm entlang der Koordinatenachsen erweitert wird. Die Intensität der erhaltenen Spektren wird in der Bildhelligkeit kodiert: Weiß entspricht der maximalen Intensität des reflektierten Signals, Schwarz der minimalen.

2.2 Inverse Aufgaben

Die OCT-Methode basiert auf der Lösung des inversen Problems. Zur Formulierung der inversen Aufgabe wird zunächst die Direktaufgabe eingeführt.

$$y(t) = \int_0^t h(t - \tau, x) x(\tau) d\tau \quad (2.28)$$

Die Gleichung 2.28 beschreibt die Berechnung des Ausgangssignals $y(t)$ aus dem bekannten Eingangssignal $x(t)$ und der Impulsantwort $h(t, x)$ der betrachteten Struktur. Sie legt damit die Grundlage für die inverse Aufgabe, bei der aus einem gegebenen Ausgang $y(t)$ das Eingangssignal $x(t)$ oder die Systemparameter bestimmt werden sollen. Um dieses Problem zu lösen, sind drei Bedingungen erforderlich:

- Das Problem hat eine Lösung (Existenz).
- Diese Lösung ist eindeutig bestimmt (Eindeutigkeit).
- Diese Lösung hängt stetig von den Eingangsdaten ab.

Für Mustererkennungsprobleme wurde durch die Theorie der gleichmäßigen Konvergenz von Häufigkeiten zu Wahrscheinlichkeiten, wie von V. N. Wapnik und A. Y. Chervonenkis entwickelt, nachgewiesen, dass unter bestimmten Bedingungen eine Lösung existiert und eindeutig ist[44]. Voraussetzung dafür ist ein ausreichend großer Datensatz, der eine gleichmäßige Annäherung des empirischen Fehlers an den wahren Fehler gewährleistet. Zudem muss der Entscheidungsraum begrenzt werden. Selbst wenn eine Aufgabe intern keine eindeutige Lösung hat, kann durch die Einführung von Einschränkungen die instabilsten Lösungen ausgeschlossen und eine praktikable Annäherung gefunden werden. Eine mögliche Methode zur Einführung von Einschränkungen ist die Regularisierung, die historisch von A. N. Tikhonov entwickelt wurde[41]. Die Anwendung

von Formel 2.28 ist für numerische Berechnungen nicht optimal und wird daher in Matrixform dargestellt. Der Übergang zu Matrizen erfolgt dadurch, dass nur der lineare Teil der Funktionen berücksichtigt wird, wenn diese in eine Taylor-Reihe zerlegt werden:

$$x \xrightarrow{f} y, \quad \exists \frac{df}{dx} \quad (2.29)$$

$$T(f) = c + A \cdot x \sim y \quad (2.30)$$

$$A^{-1}[y - c] = A^{-1} \cdot A \cdot x \quad (2.31)$$

Die umgeschriebene Definition des inversen Problems lautet wie folgt:

$$X = A^{-1}Y \quad (2.32)$$

wobei X die Matrix des Ausgangssignals, A die Matrix der Systemparameter und Y die Matrix des Eingangssignals ist.

Um die Nachhaltigkeit der Lösung eines inversen Problems zu gewährleisten, wird eine Strafe für irrelevante Lösungen eingeführt.

$$\min_X \{ \|A \cdot X - Y\|^2 + \lambda \cdot \|X\|^2 \} \quad (2.33)$$

wobei der erste Term den quadratischen Fehler zwischen der Modellvorhersage $A \cdot X$ und den gegebenen Daten Y misst, während der zweite Term als Regularisierungs- bzw. Strafterm fungiert und große Werte von X unterdrückt. Der Parameter λ steuert die Stärke der Regularisierung und bestimmt somit das Verhältnis zwischen Datenanpassung und Glattheit der Lösung.

2.3 Herausforderungen bei der digitalen Signalverarbeitung

2.3.1 Abtastung der Signal

Für eine analytische Untersuchung von Signalen ist deren präzise und kontinuierliche Darstellung erforderlich. In der Praxis handelt es sich bei realen Signalen jedoch meist um eine Überlagerung mehrerer Signalquellen mit zusätzlichem Rauschen. Die daraus resultierende analytische Beschreibung stellt daher eine komplexe Zusammensetzung von Funktionen dar, die dem gemessenen Signal lediglich angenähert ist, es jedoch nicht exakt widerspiegelt. Zudem ist die Signalverarbeitung auf modernen Computersystemen ausschließlich in diskreter Form möglich, was auf die Struktur von Speichereinheiten sowie die zugrunde liegenden Rechenprinzipien zurückzuführen ist. Aus diesen Gründen muss jedes Signal vor der digitalen Verarbeitung einer Abtastung unterzogen werden. Die dabei verwendete Abtastfrequenz muss den Anforderungen des Nyquist–Shannon-Theorems genügen[39].

$$f_s \geq 2f_{\max} \quad (2.34)$$

wobei f_s die Abtastfrequenz (Samplingrate) darstellt und $f_{\max}$ die maximale Frequenzkomponente des abzutastenden Signals ist.

Dies stellt jedoch eine allgemeine Formulierung dar, die je nach Anwendung spezifiziert werden muss. Bei Verfahren wie der optischen Kohärenztomographie (OCT) hängt die Oszillationsfrequenz eines Signals von der Änderungsrate der Phase $\varphi(\lambda)$ in Abhängigkeit von der Wellenlänge λ ab. Dies macht eine Neudefinition des Verhältnisses über eine Phase hinweg erforderlich. Dabei wird das Signal als eine oszillierende Funktion betrachtet, deren Argument eine Funktion der Wellenlänge ist.

$$S(\lambda) = \cos(\varphi(\lambda)) \quad (2.35)$$

Angenommen, die Phasenfunktion ist glatt und differenzierbar. Dadurch kann sie für λ_0 in eine Taylor-Reihe entwickelt werden.

$$\varphi(\lambda) \approx \varphi(\lambda_0) + \left. \frac{d\varphi}{d\lambda} \right|_{\lambda_0} \cdot (\lambda - \lambda_0) + \dots \quad (2.36)$$

Unter Berücksichtigung nur der linearen Terme entspricht die erste Ableitung der Phase der lokalen Frequenz, mit der sich die Phase in Abhängigkeit von der Wellenlänge ändert. Die Division dieser Größe durch 2π ergibt die Anzahl der Schwingungen pro Wellenlängeneinheit.

$$f_\lambda = \frac{\omega_\lambda}{2\pi} = \frac{1}{2\pi} \left| \frac{d\varphi}{d\lambda} \right| \quad (2.37)$$

Die Anwendung des Nyquist-Kriteriums liefert das Verhältnis für die minimale Abtastzeit, bei der eine sich ändernde Kosinusphase des Signals noch vollständig rekonstruiert werden kann.

$$T_{\text{sampl}} \leq \frac{\pi}{\left| \frac{d\varphi}{d\lambda} \right|} \quad (2.38)$$

wobei $T_{\text{sampl}} = \frac{1}{f_s}$ der Abtastzeitpunkt ist, d. h. der Kehrwert der Abtastfrequenz.

Der Effekt der Signalverzerrung bei unzureichender Abtastfrequenz wird Aliasing genannt. Bei zu großem Abtastschritt wird das Signal falsch erfasst und kann nicht fehlerfrei rekonstruiert werden.




Abbildung 2.13: Demonstration des Aliasing-Effekts bei zu großem Abtastschritt

2.3.2 Metrik

Um verschiedene Signale miteinander zu vergleichen, ist es notwendig, den Begriff der Metrik einzuführen[14]. Eine Metrik ist eine Funktion, die den Abstand zwischen zwei Objekten in einem mathematischen Raum definiert. Dieser Abstand kann als Maß für die Ähnlichkeit oder Verschiedenheit der Objekte interpretiert werden. Sei beispielsweise $d(x, y)$ eine Funktion, die für ein Paar von Punkten x und y einen reellen Wert angibt. Damit diese Funktion eine Metrik darstellt, müssen vier Axiome erfüllt sein:

$$d(x, y) = 0 \Leftrightarrow x = y \quad (\text{Axiom der Identität}) \quad (2.39)$$

Dies bedeutet, dass der Abstand zwischen zwei Punkten x und y nur dann Null ist, wenn diese Punkte übereinstimmen.

$$d(x, y) \geq 0 \quad (\text{Axiom der Positivität}) \quad (2.40)$$

Der Abstand zwischen zwei Punkten x und y kann nicht negativ sein. Es ist immer größer oder gleich Null.

$$d(x, y) = d(y, x) \quad (\text{Axiom der Symmetrie}) \quad (2.41)$$

Das heißt, die Richtung hat keinen Einfluss auf die Länge des Pfades zwischen den beiden Punkten.

$$d(x, z) \leq d(x, y) + d(y, z) \quad (\text{Axiom der Dreiecksungleichung}) \quad (2.42)$$

Der Abstand zwischen zwei Punkten x und z ist nicht größer als die Summe der Abstände von x zu einem Zwischenpunkt y und von y zu z . Daher stellt die gerade Linie die kürzeste Verbindung zwischen zwei Punkten dar.

Da das Hauptthema dieser Arbeit maschinelles Lernen und die Entwicklung von Algorithmen in diesem Bereich ist, werden im Folgenden einige der gängigen Metriken vorgestellt, die für künstliche neuronale Netze verwendet werden. Eine dieser Metriken ist die L1-Metrik (auch als

Summe der absoluten Abweichungen bezeichnet):

$$L_1(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2.43)$$

wobei x_i und y_i die Koordinaten der Punkte x und y sind.

Ein weiteres Beispiel für eine Metrik ist der MSE (Mean Squared Error) - mittlere quadratische Abweichung.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.44)$$

wobei y_i die wahren Werte und $\hat{y}_i$ die vom Modell vorhergesagten Werte sind.

Der MSE ist empfindlich gegenüber großen Fehlern, da die quadrierte Operation den Einfluss von großen Abweichungen verstärkt.

2.3.3 Rauschen

Bei signalbezogenen Prozessen tritt stets eine Wechselwirkung mit Rauschen auf. Dieses Rauschen kann sowohl externer als auch interner Natur sein. Als externe Rauschquellen gelten beispielsweise die Instabilität des Mediums, in dem sich das Signal ausbreitet – wie atmosphärische Strömungen, kosmische Strahlung oder elektromagnetische Emissionen anderer Geräte. Internes Rauschen hingegen wird durch die Eigenschaften und Parameter der Systeme bestimmt, die an der Erzeugung, Verarbeitung oder Detektion von Signalen beteiligt sind. Zu den für elektronische Geräte typischen Rauscharten gehören[10]:

- **Thermisches Rauschen** - Jedes elektronische System ist temperaturabhängigen Veränderungen seiner Bauteilparameter unterworfen. Die Zunahme der thermischen Energie innerhalb des Systems führt zur Erzeugung zufälliger Spannungs- oder Stromschwankungen.

$$v_n = \sqrt{4k_B T R_i \Delta f} \quad (2.45)$$

wobei k_B die Boltzmann-Konstante, T die absolute Temperatur, R_i der elektrische Widerstand und Δf die Bandbreite ist.

- **Schrotrauschen** - Aufgrund der diskreten Natur elektrischer Ladungsträger entstehen Stromfluktuationen, die unabhängig von Temperatur und thermischer Bewegung sind. Diese treten besonders bei niedrigen Strömen und geringen Frequenzen in Form zufälliger Stromimpulse in Erscheinung.

$$i_n = \sqrt{2e \cdot I_{CCD} \cdot \Delta f} \quad (2.46)$$

wobei e die Elementarladung, I_{CCD} der elektrische Strom im CCD und Δf die Bandbreite ist.

- **1/f-Rauschen (Flicker-Rauschen)** - Materialdefekte in elektronischen Bauelementen verursachen Inhomogenitäten im Ladungsträgerfluss. Diese führen zu niederfrequentem Rauschen, dessen Intensität mit sinkender Frequenz ansteigt.

$$S(f) = \frac{A}{f} \quad (2.47)$$

wobei A eine empirische Konstante ist




Abbildung 2.14: Vergleich verschiedener Rauschtypen mit angepassten Parametern: $R = 6,04 \times 10^{16} \Omega$, $I = 4,30 \times 10^{-19} \text{ A}$, $A = 2,51 \times 10^{-1}$

Im Frequenzbereich weisen sowohl thermisches Rauschen als auch Schrottrauschen ein spektral flaches Verhalten auf und werden daher als weißes Rauschen klassifiziert. Das Flickerrauschen hingegen zeigt eine deutlich höhere Intensität im Niederfrequenzbereich und nimmt mit steigender Frequenz kontinuierlich ab, was einem spektralen Verlauf entspricht, der typischerweise als rosa Rauschen bezeichnet wird.

2.4 Maschinelles Lernen(ML)

Maschinelles Lernen ist ein Bereich der Informatik, der sich mit der Entwicklung von Algorithmen und mathematischen Modellen befasst. Diese Modelle sind in der Lage, statistische Muster und strukturelle Zusammenhänge in Daten zu erkennen[36]. Auf Grundlage dieser Muster können sie für Vorhersagen oder Entscheidungsfindungen eingesetzt werden, ohne dass jede Aufgabe explizit programmiert werden muss.

Der Entwicklungsprozess eines maschinellen Lernalgorithmus(Abbildung 2.15) beginnt mit der Auswahl der Modellstruktur(M) und der Definition der zu lernenden Parameter. Anschließend werden die Trainingsdaten(D) dem Modell zugeführt, um dessen Anpassung zu ermöglichen. Während des Lernens vergleicht der Algorithmus seine Vorhersagen mit den bekannten Ergebnissen der Trainingsdaten. Die Fehler werden als Differenz zwischen den prognostizierten und den tatsächlichen Werten berechnet. Bei größeren Fehlern erfolgt eine Anpassung der Modellparameter(P), um die Abweichung zwischen Vorhersage und Realität zu reduzieren. Dieser Zyklus wird solange wiederholt, bis die Fehler hinreichend klein sind und das Training abgeschlossen

werden kann.




Abbildung 2.15: Ein vereinfachter Algorithmus zur Modellentwicklung im Rahmen des maschinellen Lernens zur Generalisierung von Daten. D – Menge der Ausgangsdaten, M – ausgewähltes mathematisches Modell, F – Berechnung der Abweichungen der Vorhersagen von den Ausgangsdaten, P – Prozess der Kalibrierung der Parameter des mathematischen Modells.

Nach Abschluss des Trainings erfolgt die Evaluierung (Validation) auf einem vollständig neuen Testdatensatz, um die Leistungsfähigkeit und die Fähigkeit zur korrekten Vorhersage auf unbekannten Daten zu bewerten.

2.4.1 Kernbegriffe des maschinellen Lernens

Da der Bereich des maschinellen Lernens sehr umfangreich ist und eine Vielzahl an Terminologie (überwiegend Anglizismen) umfasst, beschränkt sich diese Arbeit auf die Darstellung einiger zentraler Begriffe, die im Folgenden häufig verwendet werden. Jeder dieser Begriffe wird zusätzlich mit der ursprünglichen englischen Bezeichnung angegeben.

Künstliches neuronales Netz (neural network) – ein mathematisches Modell, das von der Struktur und den Funktionsprinzipien biologischer neuronaler Netzwerke inspiriert ist und zur Informationsverarbeitung sowie zur Lösung von Aufgaben wie Klassifikation, Regression oder Mustererkennung dient. Es besteht aus einer Vielzahl miteinander verbundener Knoten (Neuronen), die in Schichten organisiert sind (Abbildung 2.16). Die Eingabeschicht nimmt die Daten auf. Eine oder mehrere versteckte Schichten verarbeiten diese mithilfe von Gewichten (Weights), die die Stärke des Einflusses eines Neurons auf ein anderes bestimmen. Zudem werden Aktivierungsfunktionen eingesetzt, die Nichtlinearitäten einführen und als Filter der Werte wirken. Die Ausgabeschicht liefert das Vorhersageergebnis. Während des Trainings passt das Netz die Verbindungsgewichte zwischen den Neuronen auf Basis einer Verlustfunktion an, um den Vorhersagefehler zu minimieren. Die Zusammenfassung einer Menge von Neuronen wird als vollständig verbundene Schicht (Fully Connected Layer) bezeichnet.




Abbildung 2.16: Schema eines Neurons eines künstlichen neuronalen Netzes. Den Eingabewerten x werden Gewichtswerte w_k zugewiesen, die anschließend summiert und durch eine Aktivierungsfunktion φ geleitet werden. y – Ausgangswerte des Neurons.

Faltung(convolution) – eine lineare mathematische Operation, die zur Erkennung lokaler Korrelationen in Daten angewendet wird, die üblicherweise eine räumliche oder zeitliche Struktur aufweisen, wie z. B. Bilder oder Signale. Formal wird sie durch die Faltung des Eingangstensors mit einem Kern (Kernel) fester Größe realisiert, was dem Berechnen einer gleitenden Summe der Produkte der Kernel-Elemente und der lokalen Bereiche des Eingabedaten entspricht. Dieser Prozess ermöglicht die Merkmalsextraktion, da derselbe Kern auf alle lokalen Bereiche angewendet wird. Die Faltungsparameter, wie Schrittweite (Stride) und Auffüllung (Padding), erlauben die Kontrolle der Auflösung und der Größe der Ausgabefunktion. Dabei sind insbesondere die Parameter «Kernel», «Stride» und «Padding» diejenigen, die im Verlauf des Trainings des Algorithmus verändert und angepasst werden. Im Kontext eines Faltungsnetzwerks stellen diese Parameter die Gewichte (Weights) dar.




Abbildung 2.17: Beispiel für die Anwendung der Faltung auf ein zweidimensionales Datenarray. I – Ausgangsmatrix, K – Faltungskern (Kernel), IK – Ausgabematrix der Faltungsoperation[32]

Transponierte Faltung (transposed convolution) - eine lineare mathematische Operation, um die räumliche Größe der Eingabedaten zu vergrößern. Im Gegensatz zur Faltung, bei der die Eingabedaten verdichtet werden, erfolgt bei der transponierten Faltung eine Vergrößerung der räumlichen Dimension der Daten (Abbildung 2.18). Dies geschieht durch das Einfügen von Zwischenwerten (z. B. Nullen) zwischen den ursprünglichen Datenpunkten, gefolgt von der Faltung mit einem Kern (Kernel). Durch diesen Prozess werden die Informationen der Eingabe-

daten auf einen größeren räumlichen Bereich verteilt, wodurch die Auflösung der Ausgabedaten erhöht wird. Die Lernparameter – der Kern(Kernel), die Schrittweite (Stride) und die Auffüllung (Padding) – bestimmen hierbei die genaue Verteilung und Überlappung der Werte, sodass die transponierte Faltung ebenfalls trainierbar ist und Merkmale sinnvoll rekonstruiert werden können.




Abbildung 2.18: Beispiel für die Anwendung der Faltung auf ein

Epoche (epoch) – ein vollständiger Durchlauf des gesamten Trainingsdatensatzes durch das Modell, während dessen jede Trainingsinstanz zur Berechnung der Fehlerfunktion herangezogen wird und zur Anpassung der Modellparameter beiträgt.

Lernrate (learning rate) – ein Parameter beim Training eines neuronalen Netzes, der die Größe des Schritts bestimmt, mit dem die Gewichte des Modells bei der Minimierung der Verlustfunktion angepasst werden. Mit anderen Worten legt sie fest, wie stark die Parameter des Netzes nach jeder Gradientenberechnung verändert werden. Ist der Schritt zu groß, kann der Aktualisierungsprozess instabil werden und nicht zum Minimum der Verlustfunktion konvergieren, während bei einem zu kleinen Schritt die Konvergenz verlangsamt wird und das System mehr Iterationen benötigt, um einen optimalen Zustand zu erreichen.

2.4.2 Generatives Netzwerk am Beispiel von CycleGAN

Dank der Fähigkeit künstlicher neuronaler Netze, Muster aus Daten zu extrahieren, können sie als Datengeneratoren eingesetzt werden. In der Terminologie des maschinellen Lernens werden solche Netze als GAN (Generative Adversarial Network) bezeichnet[16]. Das einfachste GAN-Modell besteht aus zwei gegeneinander arbeitenden Netzwerken: dem Generator und dem Diskriminator (Abbildung 2.19). Der Generator versucht, aus zufälligem Rauschen Daten zu erzeugen, die den gewünschten (echten) Daten ähneln. Die generierten Daten werden dem Diskriminator zugeführt, der die erzeugten Daten mit den realen Daten vergleicht. Auf diese Weise strebt der Generator danach, möglichst realistische Daten zu erzeugen, während der Diskriminator immer besser darin wird, zwischen generierten und echten Daten zu unterscheiden.




Abbildung 2.19: Schema eines einfachen GAN-Netzwerks mit Generator und Diskriminator

Es existiert eine Vielzahl von GAN-Architekturen, bei denen mehrere Netzwerke auf komplexe Weise miteinander kombiniert werden können. In dieser Arbeit soll der Fokus auf einer speziellen Struktur, dem CycleGAN[54], liegen (Abbildung 2.20), die sich durch einen einzigartigen Ansatz von den übrigen Architekturen unterscheidet. Die Wahl begründet sich darin, dass die Architektur in ihrer Struktur der Lösung eines inversen Problems (Abschnitt 2.2) ähnelt, welches der Methode der OCT (Abschnitt 2.1.3) zugrunde liegt.




Abbildung 2.20: Schema von CycleGAN[54]

Das Hauptmerkmal von CycleGAN besteht darin, dass es auf nicht verknüpften Datensätzen verwendet werden kann. Es gibt anfangs keine direkte Übereinstimmung zwischen Objekten aus der Domäne A und Objekten aus der Domäne B. Zwei faltende neuronale Netze transformieren die Daten von einem Datensatz in den anderen. Das erste Netzwerk führt die Transformation $G: A \rightarrow B$ aus, während das zweite Netzwerk die umgekehrte Transformation $F: B \rightarrow A$ vornimmt. Zusätzlich gibt es zwei weitere neuronale Netze, D_A und D_B , die ebenfalls faltend sein können, aber dies ist nicht zwingend erforderlich. Diese Netze prüfen die Ergebnisse der Generierung durch die beiden Hauptnetzwerke. Der Gesamtfehler des Modells wird entsprechend berechnet.

$$\mathcal{L}(G, F, D_A, D_B) = \mathcal{L}_{\text{GAN}}(G, D_B, A, B) + \mathcal{L}_{\text{GAN}}(F, D_A, B, A) + \lambda \mathcal{L}_{\text{cyc}}(G, F) \quad (2.48)$$

wobei G der Generator von Domain A nach Domain B, F der Generator von Domain B nach Domain A, D_A der Diskriminator für Domain A, D_B der Diskriminator für Domain B und λ das Gewicht für den zyklischen Konsistenzverlust (Regularisierung).

Der Lernprozess besteht auch darin, das folgende Problem zu lösen:

$$G^*, F^* = \arg \min_{G, F} \max_{D_A, D_B} \mathcal{L}(G, F, D_A, D_B) \quad (2.49)$$

Die G - und F -Netzwerke versuchen, Daten aus Domänen zu erstellen, die dem Original am nächsten kommen. Die D_A - und D_B -Netzwerke bemühen sich, die generierten Daten so gut wie möglich von echten Daten zu unterscheiden. Zwei dieser Ansätze konkurrieren miteinander.

3. Modellentwicklung und Implementation

Die Entwicklung von Algorithmen zur Spektralanalyse in der Weißlichtinterferometrie ist stark von den spezifischen Versuchsparametern abhängig. Für jeden Proben typ muss ein exakt definierter Scanrahmen festgelegt werden. Auf Basis zahlreicher Spektralaufnahmen eines bestimmten Bereichs erfolgt das Training neuronaler Netze. Dieser Ansatz weist jedoch eine begrenzte Generalisierungsfähigkeit hinsichtlich der physikalischen Signalstruktur auf und lässt sich nur eingeschränkt auf andere Messbereiche übertragen. Im Folgenden wird der Entwicklungsprozess eines Algorithmus (Abbildung 3.1) auf Basis neuronaler Netze (insbesondere GAN) vorgestellt, der in der Lage ist, die physikalischen Parameter aus den Messdaten zu extrahieren und den einen Datenbereich aus dem anderen zu rekonstruieren. Ein zentrales Merkmal des Algorithmus ist die Anwendung nicht nur eines statistischen Ansatzes (maschinelles Lernen), sondern auch eines deterministischen Ansatzes. Das Training des Algorithmus umfasst dabei nicht nur Messdaten, sondern auch Parameter des detektierenden Systems, das diese Daten liefert. Dies wird genau die Flexibilität der Datenanalyse mithilfe neuronaler Netze in der Weißlichtinterferometrie erweitern und den Prozess in unterschiedlichen Signalbereichen vereinfachen. Als Anwendungsbereich, für den der Algorithmus entwickelt werden soll, wurde die Profilometrie gewählt, da sie über ein einfaches physikalisches Modell verfügt. Zusätzlich wird auch die Möglichkeit untersucht, einen ähnlichen Ansatz des maschinellen Lernens auf die Analyse der Tomographie geschichteter Proben anzuwenden.




Abbildung 3.1: Schema des entwickelten Algorithmus zur Verarbeitung von Signalen in der Weißlichtinterferometrie. 1 – Pfad der Transformation der Probenparameter in die entsprechenden Spektren, 2 – Pfad der Transformation des Spektrums in die Probenparameter, auf deren Grundlage es erzeugt wurde. Δ – optische Weglängendifferenz, die die Position der reflektierenden Oberfläche des untersuchten Objekts charakterisiert.

Ein wesentliches Merkmal der Entwicklung von Algorithmen des maschinellen Lernens ist, dass deren Erstellung, Kalibrierung und Überprüfung auf einer kontinuierlichen Abfolge von Versuch

und Irrtum basiert. Eine vollständige Beschreibung des Prozesses von der Ausgangssituation bis zum Endergebnis würde einen erheblichen Textumfang erfordern und die Einführung zahlreicher Terminologien, die alle Parameter des Trainings neuronaler Netze betreffen. Einige dieser Parameter blieben im Verlauf des Trainings nach bestimmten Schritten unverändert, sofern sie keinen messbaren Einfluss auf das Ergebnis hatten. Da es eine große Anzahl solcher Parameter gibt, kann der Einfluss vieler von ihnen selbst bei positiven Ergebnissen unklar bleiben. Aus diesem Grund werden in der vorliegenden Arbeit im Folgenden lediglich die Algorithmen in ihrer endgültigen Konfiguration dargestellt, ohne den Entstehungsprozess zu beschreiben. Abschließend wurden alle neuronalen Netzwerkmodelle mithilfe der Python-Bibliothek «Torch» erstellt.

3.1 Anwendungsfall Profilometrie

Die optische Profilometrie basiert auf der Messung der Intensität des von der Probenoberfläche reflektierten Lichts, um den Abstand zu dieser zu bestimmen. Werden solche Messungen an verschiedenen Punkten der Oberfläche unter Variation der räumlichen Koordinaten durchgeführt, lässt sich ein 2D-Profil oder eine 3D-Karte der Oberflächentopographie rekonstruieren. Für hochpräzise Profilmessungen wird häufig ein Michelson-Interferometer (Abbildung 2.3) verwendet, das die Interferenz zweier Wellen am Detektor registriert. Die registrierte Intensität wird in Formel 2.7 beschrieben, jedoch ist insbesondere das Argument des Kosinus $\Delta\varphi$ von Interesse, das von der Differenz der optischen Weglängen in den Armen des Interferometers abhängt (Formel 2.1).

$$\Delta\varphi = \frac{\omega}{c} \cdot \Delta L$$

In der Praxis hängt die Phase φ zudem von den Parametern des verwendeten Interferometersystems ab. Einer der zentralen Parameter ist die Auflösung des Spektrometers, also der minimal unterscheidbare Wert der registrierten Wellenlänge. Darüber hinaus ist das Vorhandensein eines Dispersions-Elements (Abbildung 2.10) zu berücksichtigen, sofern ein solches eingesetzt wird. Zusätzlich wird die Phase durch verschiedenes in den elektronischen Komponenten entstehendes Rauschen beeinflusst. Für eine ingenieurmäßige Beschreibung wird $\Delta\varphi$ über die Wellenlängen und nicht wie in theoretischen Herleitungen üblich über ω ausgedrückt. Unter Berücksichtigung der Parameter des Detektionssystems ergibt sich folgende Darstellung:

$$\Delta\varphi = \frac{2\pi}{\lambda} [(n(\lambda) - 1) \cdot l_n - \Delta] + \eta(\lambda) \quad (3.1)$$

wobei λ die Wellenlänge der einfallenden Strahlung bezeichnet, $n(\lambda)$ den wellenlängenabhängigen Brechungsindex des Dispersionselements angibt, l_n die Dicke dieses Elements beschreibt, Δ die geometrische Weglängendifferenz zwischen den Interferometerarmen charakterisiert und $\eta(\lambda)$ einen zusätzlichen, wellenlängenabhängigen Rauschanteil repräsentiert.

Da die Hauptaufgabe dieser Arbeit darin besteht, einen Algorithmus zu entwickeln, der Spektraldaten aus verschiedenen Messbereichen für die Weißlichtinterferometrie gut generalisieren

kann, ist es sinnvoll, die Daten selbst zu generieren. Dies ermöglicht es, zu einem späteren Zeitpunkt problemlos einen deterministischen Ansatz zu implementieren. Als Datengenerator dient ein Programmcode in Python. Diese Programmiersprache wurde gewählt, da für sie eine große Anzahl an Bibliotheken für maschinelles Lernen verfügbar ist, die im weiteren Verlauf benötigt werden. Der Code basiert auf Formel 3.1 und erzeugt Cosinus-Funktionen mit unterschiedlichen Argumenten, abhängig von den vorgegebenen Parametern. Im Anschluss an die Datengenerierung folgt eine separate Funktion zur schnellen Fourier-Transformation (FFT), um die Spektren zu erhalten. Aus den Spektren des reflektierten Signals lassen sich anschließend Rückschlüsse auf das Objekt ziehen (siehe Abschnitt 2.1.2: Fourierbereich – Weißlichtinterferometrie).




Abbildung 3.2: Schema des Datengenerators in Python. FFT – schnelle Fourier-Transformation

Da die Phase von mehreren Parametern beeinflusst wird, ist es sinnvoll, den Einfluss jedes einzelnen auf das Signal separat zu betrachten und zu untersuchen, wie diese mithilfe von maschinellem Lernen analysiert werden können.

3.1.1 Ideales Signal

Zunächst wird ein ideales Signal simuliert, ohne zusätzliche Dispersion und ohne Rauschanteile. Auf diese Weise lässt sich feststellen, welche Eigenschaften das physikalische Signal unabhängig vom realen System besitzt und mit welchen Methoden es sich am besten untersuchen lässt.

$$\varphi = \frac{2\pi}{\lambda} \cdot \Delta \quad (3.2)$$

Der einzige Parameter, der hier vom interferometrischen System beeinflusst wird, ist der Wellenlängenbereich λ sowie der Schritt zwischen den einzelnen Messpunkten. Da für Untersuchungen, beispielsweise in der OCT, Infrarotquellen verwendet werden, wird ein für diese typischer Bereich von $1 \mu\text{m}$ bis $2,5 \mu\text{m}$ gewählt. Bezüglich des Schritts wird zur Anpassung des Algorithmus an ein herkömmliches Spektrometer ein Wert von 2 nm verwendet. Diese Auflösung ist typisch für gängige optische oder infrarote Profilometrie.




Abbildung 3.3: Kosinusfunktion in Abhängigkeit von φ bei einem Wert von $\Delta = 22 \mu\text{m}$

Setzt man das Argument φ in den Kosinus ein, erhält man eine oszillierende Kurve (Abbildung 3.3), deren Frequenz von λ abhängt. Bei kleinen Werten von λ erfolgen die Schwingungen sehr schnell, während die Frequenz mit zunehmendem λ abnimmt und die Schwingungen langsamer werden. Um nun Informationen aus einem solchen kosinusförmigen Signal zu gewinnen, muss eine Fourier-Transformation durchgeführt werden. Mittels der externen Bibliothek NumPy für Python wird eine diskrete schnelle Fourier-Transformation (FFT) durchgeführt und das entsprechende Spektrum im ω -Bereich erstellt.




Abbildung 3.4: Fourier-Bild der Kosinusfunktion für $\Delta = 22 \mu\text{m}$. Die vertikale Achse stellt die Amplitude der Fourier-Transformation $|F(1/\omega)|$ dar.

Im Unterschied zum konventionellen Ansatz wurde der symmetrische Anteil der negativen Frequenzen nicht verworfen, um möglichst viele Informationen für die anschließende Analyse zu erhalten. Da der Kosinus (Abbildung 3.3) für einen einzelnen Wert der optischen Weglängendifferenz Δ generiert wurde, zeigt sich nach der Transformation im Spektrum lediglich nur ein

einzigster Intensitätsspitze. Der Abstand vom Maximum des Peaks zur Nullfrequenz entspricht der optischen Weglängendifferenz, die zur Interferenz geführt hat. Als grundlegender Datensatz wurden 1000 verschiedene Kosinusfunktionen mit ihren Fourier-Spektren generiert, deren Δ -Werte gleichmäßig im Bereich von 0 bis 100 verteilt sind. Für jedes Spektrum wurde der jeweilige Wert von Δ gespeichert, auf dessen Basis es genau erzeugt wurde.

Nachdem die Daten für die Profilometrie nun generiert wurden, kann deren Analyse mithilfe von maschinellem Lernen begonnen werden. Der Datensatz lässt sich in zwei Domänen unterteilen. Domäne A besteht aus den Fourier-Spektren. In Domäne B sind die Werte der optischen Weglängendifferenz Δ enthalten, die den Abstand bis zur Reflexion des Signals von der Objektoberfläche charakterisieren. Die Untersuchung einer solchen Domänenstruktur lässt sich gut im Hinblick auf die Architektur von CycleGAN (Abbildung 3.5) betrachten, die mehrere Domänen über Transformationen mithilfe neuronaler Netze miteinander verbindet. Der eigentliche Prozess der Informationsgewinnung aus interferometrischen Messdaten ähnelt dabei der Transformation einer Domäne in die andere, wie sie in CycleGAN durchgeführt wird.




Abbildung 3.5: Schematische Darstellung der Kombination zweier Transformationsnetzwerke der Domänen A und B in einem CycleGAN. G – Funktion zur Transformation des Spektrums in den Wert der optischen Weglängendifferenz Δ , F – Funktion zur Rücktransformation von Δ in das Spektrum

Der traditionelle Ansatz in CycleGAN besteht darin, Faltungsnetze als Funktionen für die Transformation von Domäne A in Domäne B einzusetzen. Wir bezeichnen die direkte Funktion als G und die inverse als F . Anschließend wird jede der Transformationen einzeln betrachtet und die Struktur der neuronalen Netze beschrieben. Besonders vorteilhaft ist hierbei, dass beide Domänen als eindimensionale Vektoren vorliegen. Dies vereinfacht die Berechnungen und vermeidet Probleme, die unvermeidlich auftreten, wenn Daten unterschiedlichen Typs transformiert werden (z. B. Bild zu Vektor und zurück), bei denen zwangsläufig Informationsverlust oder Verzerrungen in der Generierung auftreten.

3.1.1.1 Transformation $G: A \rightarrow B$

Die Funktion von G besteht darin, aus einem langen eindimensionalen Vektor A lediglich einen skalaren Wert B zu gewinnen (Abbildung 3.6). Die erste Schicht des Netzes wendet eine Faltungsoperation auf den ursprünglichen Vektor an. Es werden 8 verschiedene Faltungskerne initialisiert, die über die Spektralwerte laufen und lokale Merkmale extrahieren. Die zweite Schicht führt dieselbe Operation auf den Kombinationen dieser Merkmale aus und extrahiert dabei komplexere, abstraktere Muster. Um die Mehrkanaligkeit zu beseitigen, wird die Struktur vektorisiert und zu einem einzigen langen Vektor zusammengeführt. Der abschließende Schritt der Transformation ist eine vollverbundene Schicht. Deren Eingang ist ein Vektor der Größe $[1 \times 16000]$, während der Ausgang lediglich einen einzelnen Skalarwert liefert. Jedem Element des Vektors wird ein statistisches Gewicht zugeordnet, das seinen Beitrag zum Endergebnis bestimmt. Nach zahlreichen Initialisierungsprozessen der G -Funktion speichert das Netzwerk innerhalb dieser Funktion Informationen darüber, welche Vektorbereiche am wichtigsten sind und nach allen Transformationen das Resultat maßgeblich beeinflussen.




Abbildung 3.6: Schema der G -Transformation für ein einzelnes Spektrum. Conv2d – Faltungsoperation, Flatten – Vektorisierung, Linear – vollständig verbundene Schicht.

Beim Training des neuronalen Netzwerks werden zahlreiche Berechnungen der Funktionsgradienten sowie Tensor-Multiplikationen durchgeführt. Mathematische Operationen mit mehrdimensionalen Tensoren, die eine große Anzahl von Variablen enthalten, erfordern eine erhebliche Rechenleistung. Zur Optimierung des Trainingsprozesses wurden die Daten vorab normalisiert. Eine effektive Methode zur Vereinfachung der Berechnungskomplexität besteht darin, alle Werte auf einen Bereich zwischen 0 und 1 zu skalieren. Für Spektren in der Domäne A erfolgte die Normalisierung mittels einer Skalierung, die auf den kardinalen Werten des jeweiligen Spektrums basierte.

$$\tilde{A}_i = \frac{A_i - \min(A)}{\max(A) - \min(A) + \varepsilon} \quad (3.3)$$

wobei das Symbol A_i bezeichnet den Wert des Spektrums, während $\varepsilon = 10^{-8}$ eine kleine Zahl ist, die verwendet wird, um eine Division durch null zu vermeiden.

Für skalare Werte in der Domäne B genügt eine einfache Division durch 100.

$$\tilde{B} = \frac{B}{100} \quad (3.4)$$

Im nächsten Schritt wird überprüft, wie gut das trainierte neuronale Netzwerk in der Lage ist, neue Daten vorherzusagen. Das trainierte Convolutional Neural Network (CNN) besteht aus der gespeicherten Struktur seiner Schichten sowie den während des Trainings erlernten Faltungsparametern (Gewichten), die so angepasst wurden, dass die Vorhersagen des Netzwerks den tatsächlichen Werten möglichst genau entsprechen. Zur Validierung des Modells wurden 100 zusätzliche Spektren aus demselben Wertebereich wie die Trainingsdaten herangezogen. Diese neuen Spektren werden durch das Netzwerk geführt, um die entsprechenden Vorhersagen zu erhalten. Dabei bleibt die Netzwerkstruktur unverändert, und die intern erlernten Gewichte werden nicht modifiziert. Die Ergebnisse der Validierung (Abbildung 3.7) zeigen, dass die gewählte Netzwerkarchitektur nahezu ideal in der Lage ist, den Wert von Δ aus einem Spektrum zu bestimmen.




Abbildung 3.7: Das Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Transformation («Epoch» = 30, «Learning rate» = 10^{-3}). Alle Werte wurden gemäß Formel 3.4 normalisiert.

3.1.1.2 Transformation $F: B \rightarrow A$

Die Funktion F dient der Rekonstruktion eines eindimensionalen Spektrums aus einem skalaren Wert, d.h., sie realisiert die inverse Transformation der zuvor angewandten Operation (Abschnitt 3.1.2). Zur Dimensionserweiterung wird die transponierte Faltung (transposed convolution) eingesetzt, die im Unterschied zur Standardfaltung die Größe des Ausgabevektors vergrößert, indem sie in jeder Schicht zusätzliche Elemente einfügt (Abbildung 3.8). Auf diese Weise kann der Vektor schrittweise auf die erforderliche Länge gebracht werden.

Der Beginn mit einem einzelnen Skalar führt zu einem Ungleichgewicht der Schicht-Einflüsse: Die erste Schicht der transponierten Faltung dominiert den Endwert unverhältnismäßig stark. Zur Lösung dieses Problems wird die erste Schicht als vollständig verbundene Schicht (fully connected layer) implementiert, die den Skalar in einen mehrkanaligen Vektor geringer Dimension $[16 \times 4]$ transformiert und so eine gleichmäßige Informationsverteilung sowie initiale Flexibilität der Modellstruktur gewährleistet. Die ausschließliche Verwendung einer vollständig verbundenen Schicht würde die Trainierbarkeit des Netzwerks einschränken, da das Modell lediglich die Gewichtungen reproduziert, ohne generalisierbare Muster zu erlernen. Die nachfolgenden transponierten Faltungsschichten führen Variabilität ein, erhöhen die Anpassungsfähigkeit an die Eingabedaten und ermöglichen die Ausbildung komplexer Strukturen im Ausgabevektor. Durch die sequentielle Anwendung von vier transponierten Faltungsschichten erfolgt eine schrittweise Reduktion der Kanalanzahl bei gleichzeitiger Erhöhung der Vektorlänge bis zur erforderlichen Dimension $[1 \times 1000]$, wodurch eine ausgewogene Einflussverteilung der Schichten auf das finale Ergebnis erreicht wird.




Abbildung 3.8: Schema der F-Transformation für einen einzelnen Wert der optischen Wegdifferenz. Linear – vollständig verbundene Schicht, ConvTransposed2d – transponierte Faltungsoperation.

Der Prozess der Normalisierung der Daten vor dem Training wurde auf analoge Weise wie bei der Transformation G unter Verwendung der Formeln 3.3 und 3.4 durchgeführt. Für die Validierung musste jedoch die Darstellung der Daten leicht angepasst werden, um die Berechnungen zu erleichtern. Der deterministische Algorithmus, der als Datengenerator fungierte, erzeugte Spektren mit korrekter Darstellung negativer und positiver Frequenzen (Abbildung 3.4). Im maschinellen Lernen wird jedoch möglichst darauf geachtet, negative Werte zu vermeiden, um die Berechnungen zu vereinfachen. Daher enthalten die Spektren bei der Validierung nur positive Werte f – eine neue Frequenzdarstellung. Für einen korrekten Vergleich wurden auch die tatsächlichen Spektren entsprechend verschoben, ausschließlich zur Veranschaulichung (Abbildung 3.9).




Abbildung 3.9: Das Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die F-Umwandlung («Epoch» = 50, «Learning rate» = 10^{-4}). Beide Spektren wurden für den Wert der optischen Wegdifferenz $\Delta = 22 \mu\text{m}$ erzeugt. Der Wert der vertikalen Achse der Amplitude ist gemäß Formel 3.4 normalisiert, während die horizontale Achse stellt die nach FFT in den positiven Bereich verschobenen Frequenzen f dar.

Die Trainingsergebnisse ließen sich nur schwer mit den im maschinellen Lernen üblichen Metriken beurteilen. Weder MSE noch L1-Metriken (Abschnitt 2.3.2) liefern aussagekräftige Bewertungen der Leistungsfähigkeit des Netzwerks bei der Transformation F . Sie vergleichen lediglich die Werte beider Vektoren und geben die mittlere Abweichung aus. Für die untersuchten oszillierenden Signale ist ein solcher Mittelungsansatz vollkommen ungeeignet, da die Signalform dabei vollständig verloren geht. Daher wurde beschlossen, die Trainingsergebnisse mittels visueller Validierung zu überprüfen.

Ein Beispiel für die Vorhersage eines Spektrums durch das Netzwerk für den entsprechenden Wert von Δ ist in Abbildung 3.9 dargestellt. Es ist erkennbar, dass die Rekonstruktion des Spektrums durch das Netzwerk nur eine geringe Genauigkeit aufweist. Die Oszillationen an den Rändern der Peaks werden nicht reproduziert und erscheinen lediglich als verrauschtes Signal mit zufälligen Amplitudenfluktuationen. Die Form des Peaks wird nicht wiedergegeben, jedoch wird dessen Position annähernd korrekt bestimmt. Positiv hervorzuheben ist, dass zumindest die Frequenzen der Peaks näher an der Realität liegen. Für Werte in der Nähe des Maximums des generierten Bereichs von Δ (Abbildung 3.10b) ist die Ähnlichkeit mit dem tatsächlichen Spektrum deutlicher ausgeprägt. Auch hier werden die Oszillationen nicht präzise rekonstruiert, jedoch nähern sich die Peaks stärker ihrer tatsächlichen Form an. Am wenigsten erfolgreich ist die Reproduktion der Spektren für kleine Werte von Δ (Abbildung 3.10a). In diesem Fall weisen die vorhergesagten Spektren nur eine minimale Übereinstimmung mit dem Original auf.




Abbildung 3.10: Visualisierung polare Fälle der Spektrumsvorhersage durch Netzwerk F («Epoch» = 50, «Learning rate» = 10^{-4}). a – Spektren wurden bei $\Delta = 1 \mu\text{m}$ erzeugt. b – Spektren wurden bei $\Delta = 100 \mu\text{m}$ erzeugt. Blaue Linie - wahres Spektrum, rote Linie - vorhergesagtes Spektrum.

3.1.1.3 Geschlossener Transformationszyklus - Kombination von G und F

Nach dem separaten Training der neuronalen Netze werden deren Eingaben und Ausgaben miteinander verknüpft, wodurch ein geschlossener Zyklus entsteht. Auf diese Weise wird die Struktur einer CycleGAN realisiert, wie in Abbildung 3.5 dargestellt. Für die Validierung wird der Ansatz leicht angepasst, indem deutlich mehr Testdaten für kleine Werte von Δ generiert werden, da dieser Bereich potenziell problematisch sein kann (Abbildung 3.11).




Abbildung 3.11: a – Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Umwandlung in CycleGAN («Epoch» = 20, «Learning rate» = 10^{-5}). b – Vergrößerung des Diagrammbereichs mit Werten für Δ zwischen 0 und 10

Das in Abschnitt 3.1.1.2 für die F -Funktion identifizierte Problem der Ungenauigkeit bei kleinen Werten überträgt sich im Zyklus auch auf die Transformation G . Bei der G -Netzwerkarchitektur

nimmt die Vorhersagegenauigkeit für Werte von $\Delta < 5$ zu (Abbildung 3.11b). Um zu verstehen, weshalb das Netzwerk in diesem Bereich Schwierigkeiten aufweist, wird im Folgenden untersucht, wie die Eingangsdaten aussehen. Zu diesem Zweck werden die Spektren für kleine Werte von Δ visualisiert.




Abbildung 3.12: a – simuliertes Spektrum nach FFT für $\Delta = 2 \mu\text{m}$. b – simuliertes Spektrum nach FFT für $\Delta = 10 \mu\text{m}$

In den Fourier-Spektren der Transformation ist deutlich eine gezackte, unruhige Struktur zu erkennen (Abbildung 3.12b). Dieser Effekt entsteht dadurch, dass anstelle einer unendlich ausgedehnten Kosinusfunktion eine zeitlich begrenzte Version verwendet wird. Wenn man mathematische Operationen an einer oszillierenden Funktion durchführt, wird in der Praxis lediglich ein begrenzter Abschnitt ihres Funktionsverlaufs betrachtet. Diese Einschränkung ergibt sich aus der Art und Weise, wie mathematische Funktionen auf modernen Computern verarbeitet werden. Um Funktionswerte im Speicher zu halten, muss die Funktion diskretisiert und auf ein endliches Zeitfenster begrenzt sein. Zunächst wird die Fourier-Transformation des idealen Kosinus ohne Normierungsfaktor betrachtet:

$$\mathcal{F}\{\cos(\omega_0 t)\} = \int_{-\infty}^{\infty} \cos(\omega_0 t) \cdot e^{-i\omega t} dt = \pi [\delta(\omega - \omega_0) + \delta(\omega + \omega_0)] \quad (3.5)$$

wobei $\mathcal{F}\{\}$ die kontinuierliche Fourier-Transformation bezeichnet, ω_0 die Kreisfrequenz der Cosinus-Funktion ist, t die Zeitvariable darstellt, ω die Frequenzvariable im Frequenzraum ist, und $\delta(\omega)$ die Dirac-Delta-Distribution symbolisiert.

Ein solches Transformationsergebnis entsteht aufgrund der Eigenschaft der Delta-Funktion

$$\delta(\omega) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{i\omega t} dt \quad (3.6)$$

Die Dirac-Delta-Funktion $\delta(\omega)$ wird definiert als eine Funktion, die die folgenden Eigenschaften

erfüllt:

$$\delta(t) = \begin{cases} 0, & \text{für } t \neq 0 \\ \infty, & \text{für } t = 0 \end{cases} \quad \text{wobei} \quad \int_{-\infty}^{\infty} \delta(t) dt = 1 \quad (3.7)$$

Bereits auf dieser Grundlage ist eine visuelle Darstellung im Spektrum problematisch. Zudem ist eine Durchführung dieser Art von Berechnung in der Praxis nicht realisierbar. In der Praxis wird die Kosinusfunktion zur Begrenzung mit einer Rechteckfunktion multipliziert, bei der es sich um eine stückweise konstante Funktion handelt, die sich wie folgt darstellen lässt:

$$\text{rect}\left(\frac{t}{T}\right) = \begin{cases} 1, & \text{für } |t| < \frac{T}{2} \\ \frac{1}{2}, & \text{für } |t| = \frac{T}{2} \\ 0, & \text{für } |t| > \frac{T}{2} \end{cases} \quad (3.8)$$

wobei T die Breite des Rechteckfensters ist. Die Funktion nimmt den Wert 1 im offenen Intervall $(-\frac{T}{2}, \frac{T}{2})$ an und ist außerhalb dieses Bereichs gleich 0 (Abbildung 3.13). An den Rändern $t = \pm \frac{T}{2}$ nimmt die Funktion den Wert $\frac{1}{2}$ an. Streng genommen ist der Wert der Funktion an den Grenzen des Intervalls nicht eindeutig definiert. Die Bedeutung der Funktion an diesen Punkten wird stets vom jeweiligen Kontext der Aufgabe bestimmt. In diesem speziellen Fall wurde der Mittelwert der Amplitude angenommen; es wären jedoch auch die Werte 0 oder 1 möglich gewesen. Hier dient die Funktion lediglich zur Veranschaulichung, ohne dass weitere Berechnungen mit ihr durchgeführt werden.




Abbildung 3.13: Darstellung des $\text{rect}\left(\frac{t}{T}\right)$ mit dem Parameter $T=2$

Das Ergebnis der Fourier-Transformation dieser Funktion (Formel 3.8) ist ein sogenannter kardinaler Sinus (sinc-Funktion). Die Form dieser Funktion bestimmt maßgeblich die Struktur des Kosinus-Spektrums nach der Fourier-Transformation (Abbildung 3.14).

$$\mathcal{F}\left\{\text{rect}\left(\frac{t}{T}\right)\right\} = T \cdot \text{sinc}\left(\frac{\omega T}{2}\right) \quad (3.9)$$




Abbildung 3.14: Darstellung des Kardinalsinus mit dem Parameter $T=2$

Nach dem Faltungssatz der Fourier-Analyse entspricht das Produkt zweier Funktionen im Zeitbereich der Faltung der jeweiligen Fourier-Transformierten im Frequenzbereich.

$$\begin{aligned}
 \mathcal{F} \left\{ \cos(\omega_0 t) \cdot \text{rect} \left(\frac{t}{T} \right) \right\} &= \frac{1}{2\pi} \left[\mathcal{F} \{ \cos(\omega_0 t) \} * \mathcal{F} \left\{ \text{rect} \left(\frac{t}{T} \right) \right\} \right] \\
 &= \frac{1}{2\pi} \left[\pi (\delta(\omega - \omega_0) + \delta(\omega + \omega_0)) * \left(T \cdot \text{sinc} \left(\frac{\omega T}{2} \right) \right) \right] \\
 &= \frac{T}{2} \left[\text{sinc} \left(\frac{\omega - \omega_0}{2} T \right) + \text{sinc} \left(\frac{\omega + \omega_0}{2} T \right) \right] \quad (3.10)
 \end{aligned}$$

So ergibt sich ein Spektrum, das aus zwei kardinalen Sinusgipfeln besteht (Abbildung 3.12b). Erschwerend kommt hinzu, dass der Kardinalsinus stets seitliche Oszillationen aufweist. Diese überlagern sich gegenseitig und verzerren das Endergebnis. Um dieses Problem zu beheben, kann eine alternative Methode verwendet werden. Es ist unumgänglich, den Kosinus zu begrenzen, da sonst kein realistisches Signal simuliert werden kann. Anstelle der Rechteckfunktion kann eine andere Modulationsfunktion eingesetzt werden. Die Gauß-Funktion stellt hierfür eine geeignete Wahl dar. Bei Quelle lassen sich beide Komponenten durch diese Funktion mit hoher Genauigkeit approximieren.

Für OCT sind Lichtquellen mit einem breiten Spektrum erforderlich. Eine wesentliche Einschränkung bei der Erzeugung eines solchen Spektrums stellt jedoch der Leistungsverlust über die Frequenzbereiche hinweg dar. Dieser wirkt sich negativ auf das Signal-Rausch-Verhältnis aus, wodurch das empfangene Signal abgeschwächt und der Interferenzkontrast reduziert wird. Aus diesem Grund kommen häufig Superlumineszenzdiode (SLDs) oder Femtosekundenlaser zum Einsatz. Für derartige Lichtquellen ist die Gauß-Funktion besonders geeignet, um das reale Spektrum präzise zu beschreiben.

Zunächst wird die Gauß-Funktion eingeführt. Der Einfachheit halber wird dabei direkt die Kreisfrequenz anstelle der Wellenlänge verwendet. Diese Entscheidung basiert auf der Tatsache,

dass sie bei einer späteren Fourier-Transformation vorteilhafter ist.

$$g(\omega, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\omega - \bar{\omega})^2}{2\sigma^2}\right) \quad (3.11)$$

wobei $g(\omega, \sigma)$ eine Gaußsche Normalverteilung in Abhängigkeit von der Frequenz ω und der Standardabweichung σ ist.

Damit die verwendete Funktion 3.11 den physikalisch realisierbaren Eigenschaften entspricht, müssen folgende Bedingungen erfüllt sein:

- Endlichkeit des Gesamtenergieinhalts – Der Energieerhaltungssatz verlangt, dass der gesamte Energieinhalt des Systems endlich ist. Eine unendlich strahlende Quelle ist physikalisch nicht realisierbar.

$$\int_0^\infty |g(\omega, \sigma)|^2 d\omega < \infty \quad (3.12)$$

- Begrenzung des Spektrums – Physikalische Quellen besitzen stets ein Spektrum endlicher Breite. Sowohl unendlich breite als auch unendlich schmale Spektren sind in realen Systemen ausgeschlossen.

$$\lim_{\omega \rightarrow +\infty} g(\omega, \sigma) = 0, \quad \lim_{\omega \rightarrow 0} g(\omega, \sigma) = 0 \quad (3.13)$$

- Glattheit des Spektrums – Die Intensitätsverteilung als Funktion der Frequenz muss differenzierbar und ihre Ableitung über den gesamten Frequenzbereich beschränkt sein. Dies ergibt sich aus der Forderung, dass das Spektrum physikalisch realisierbarer Signale keine Sprungstellen oder Singularitäten aufweist.

$$\forall \omega, \quad \exists \left| \frac{\partial g(\omega, \sigma)}{\partial \omega} \right| < \infty \quad (3.14)$$

Als Bereich der Gauß-Funktion wird die untere Grenze durch eine typische Wellenlänge eines Femtosekundenlasers (800 nm) und die obere Grenze durch das Maximum eines SLD (1300 nm) festgelegt. Diese Wahl macht die Simulation ausreichend universell, da sie die Auflösungsgrenze realistisch abbildet.

$$\omega_{\max}(\lambda = 800 \text{ nm}) = 2.36 \times 10^{15} \text{ rad } \mu\text{m}^{-1}$$

$$\omega_{\min}(\lambda = 1300 \text{ nm}) = 1.45 \times 10^{15} \text{ rad } \mu\text{m}^{-1}$$




Abbildung 3.15: Darstellung der Gaußfunktion

Ein weiterer Vorteil der Verwendung der Gauß-Funktion liegt in der speziellen Eigenschaft ihrer Fourier-Transformation.

$$\mathcal{F}\{g(\omega, \sigma)\} = \exp(-i\bar{\omega}t) \cdot \exp\left(-\frac{\sigma^2 t^2}{2}\right) \quad (3.15)$$

wobei der erste Faktor $\exp(-i\bar{\omega}t)$ eine Phasenverschiebung beziehungsweise eine Modulation mit der Trägerfrequenz $\bar{\omega}$ beschreibt, die keine Auswirkung auf die Amplitude hat, und der zweite Faktor $\exp\left(-\frac{\sigma^2 t^2}{2}\right)$ die zeitliche Hüllkurve der Gaußfunktion darstellt, welche die Breite und Form des Signals im Zeitbereich bestimmt. In diesem speziellen Fall kann der Phasenmultiplikator vernachlässigt werden, da ausschließlich der Modul der Fourier-Transformation betrachtet wird ($|\exp(-i\bar{\omega}t)| = 1$).

Das Ergebnis der Fourier-Transformation der Gauß-Funktion ist erneut eine Gauß-Funktion, jedoch im jeweils anderen Bereich. Die Form der Gauß-Funktion bleibt dabei erhalten, nur ihre Breite verändert sich. Ist die Funktion in einem Bereich (Zeit- oder Frequenzbereich) stark konzentriert, zeigt sie im jeweils anderen Bereich eine entsprechend größere Ausdehnung. Die Gauß-Funktion ist somit in beiden Bereichen lokalisiert, wobei zwischen der Breite in Zeit und Frequenz eine inverse Beziehung besteht. Im Gegensatz zum Kardinalsinus zeigt die Gauß-Funktion außerhalb des Hauptmaximums keine Oszillationen (Abbildung 3.16).




Abbildung 3.16: Darstellung der Gaußfunktion im Zeitbereich

Durch die Multiplikation der Gauß-Funktion mit dem Kosinus, dessen Phase zuvor in Gleichung 3.2 bestimmt wurde, lassen sich die unerwünschten Frequenzen ausschließen, die zu Artefakten geführt haben. Das Ergebnis dieser Multiplikation (Abbildung 3.17) wird nun in Form von Kreisfrequenzen ω dargestellt, um eine weitere Fourier-Transformation zu erleichtern.




Abbildung 3.17: Das Ergebnis der Multiplikation des Kosinus mit der Gauß-Funktion

Im Wesentlichen wurde eine Filterung durchgeführt, die den Einfluss zu hoher und zu niedriger Frequenzen im Signal entfernte und nur den mittleren Frequenzbereich beließ. Die Spektren nun sind geglättet, und die Oszillationen sind verschwunden. Bei Werten nahe Null tritt nun nicht mehr die Situation auf, dass sich die Peaks aufgrund ihrer größeren Fläche überlappen (Abbildung 3.12a). Als Nebeneffekt verschwinden jedoch die Oszillationen der Signale in der Nähe der Peaks (Abbildung 3.18). Eine derartige Filterung erleichtert nicht nur das Training der Funktion G zur Vorhersage von Werten aus dem Spektrum, sondern auch das Training der Funktion F , da das Spektrum dadurch vereinfacht wird. Die Netzwerke müssen nun nicht mehr strukturell komplexe Oszillationen verarbeiten.




Abbildung 3.18: Ergebnis der Anwendung der Gauß-Funktion auf das Signal. a – simuliertes Spektrum für $\Delta = 2$ nach Multiplikation mit Gauss-Funktion, b – simuliertes Spektrum für $\Delta = 10$ nach Multiplikation mit Gauss-Funktion

Die Trainingsergebnisse mit den mittels einer Gauß-Funktion gewichteten Spektren (Abbildung 3.19) zeigen für die Transformation G eine Verbesserung im Vergleich zu Abbildung 3.11b. Dennoch bleibt die zuvor festgestellte Tendenz bestehen: Bei der Vorhersage von Δ -Werten nahe Null weist das Netzwerk weiterhin Schwierigkeiten auf. Zu kleine Werte führen zu derart schmalen Spektren, dass das Faltungskern keine charakteristischen Merkmale extrahieren kann.




Abbildung 3.19: Ergebnis der Vorhersagekapazität eines neuronalen Netzwerks für die G-Umwandlung in CycleGAN für Δ zwischen 0 und 10 («Epoch» = 2, «Learning rate» = 10^{-5}).

Im Gegensatz dazu wirkt sich die Einführung der Gauß-Filterung bei der Transformation F positiv auf die Vorhersagegenauigkeit aus. Die Form der Peaks sowie deren Intensität werden vom Netzwerk nun nahezu exakt rekonstruiert (Abbildung 3.20).




Abbildung 3.20: Vergleich der Vorhersageergebnisse der Spektren nach Multiplikation mit der Gauß-Funktion durch das Netzwerk für die Transformation F («Epoch» = 50, «Learning rate» = 10^{-4}). Die x-Achse ist so skaliert, dass der Hauptteil der Generierung – die beiden Peaks – sichtbar wird. a – Spektren für $\Delta = 2 \mu\text{m}$, b – Spektren für $\Delta = 10 \mu\text{m}$. Blaue Linie – wahres Spektrum, rote Linie – vorhergesagtes Spektrum.

3.1.2 Dispersion im Signal

Wie bereits in Abschnitt 2.1.2 beschrieben, wird in der OCT gelegentlich Dispersion hinzugefügt. Da die Probe selbst oft eine eigene Dispersion aufweist, die das Signal verzerrt, wird versucht, diese für präzise Messungen zu kompensieren. Hierzu wird in einen Arm des Interferometers ein dispersives Element eingefügt (Abbildung 2.10). Ist dieses Element passend gewählt, ist der Dispersionseffekt im resultierenden Spektrum nicht erkennbar. Im Rahmen dieser Arbeit ist die Implementierung eines deterministischen Algorithmus vorgesehen, der physikalischen Gesetzmäßigkeiten entspricht. Es ist daher sinnvoll zu untersuchen, wie Dispersion ein ideales Signal beeinflusst. Die Phase des vom Interferometer registrierten Signals bei vorhandener Dispersion wird durch folgende Gleichung beschrieben:

$$\varphi = \frac{2\pi}{\lambda} [(n(\lambda) - 1) \cdot l_n - \Delta] \quad (3.16)$$

Die Dispersion wird über den Brechungsindex des Materials definiert (Formel 2.22). Zur Vereinfachung der Berechnungen wird im Folgenden ausschließlich der Realteil des Brechungsindex betrachtet. Ausgehend von der klassischen Lorentz-Darstellung erklärt sich die Abhängigkeit vom Brechungsindex durch das Vorhandensein von Resonanzfrequenzen (Abbildung 2.9). In der Nähe solcher Frequenzen ist die Dispersion aufgrund der Resonanz der Elektronenbewegung mit der einfallenden Welle maximal. Am Beispiel der experimentellen Abhängigkeit des Brechungsindex von der Wellenlänge für das in der Optik gebräuchliche Glas N-BK-7 (Abbildung 3.21) zeigt sich, dass bei diesem Material die Resonanz im nahen UV-Bereich liegt. Die Einführung der Dispersion dieses Materials in ein ideales Signal hat nur einen geringen Einfluss, sodass das Signal in Abbildung 3.4 nahezu unverändert bleibt.




Abbildung 3.21: Abhängigkeit des Brechungsindex von N-BK7-Glas von der Wellenlänge

Zur Demonstration des Dispersionseffekts wurden drei verschiedene Materialien mit bekannter experimenteller Abhängigkeit des Brechungsindex von der Wellenlänge ausgewählt: Kohlenstoffdisulfid (CS_2), Fused Silica das organische Material MDMO-PPV (Abbildung 3.22). Die Verwendung der ersten beiden Materialien als dispersive Elemente in der OCT ist zwar schwierig, wurde jedoch ausschließlich zu Demonstrationszwecken gewählt, um den Einfluss der Dispersion auf das Spektrum zu veranschaulichen.




Abbildung 3.22: Abhängigkeit des Brechungsindex von der Wellenlänge für verschiedene Materialien. a – Kohlenstoffdisulfid (CS_2), b – Fused Silica, c – MDMO-PPV.




Abbildung 3.23: Simulationsergebnis des Signals nach Formel 3.16 für drei verschiedene Materialien auf Basis experimenteller Daten $n(\lambda)$. a – Kohlenstoffdisulfid (CS_2), b – Fused Silica, c – MDMO-PPV.

Es zeigte sich, dass der Einfluss der Dispersion auf das Signal stark von der Form der Abhängigkeit des Brechungsindex bestimmt wird. Die Veränderung der Peak-Amplitude hängt davon ab,

wie stark sich der Brechungsindex ändert. Beim ausgeprägt nichtlinearen Brechungsindex von MDMO-PPV (c) stieg die Amplitude des Spektrums beispielsweise um ein Vielfaches an, im Gegensatz zu CS_2 (a) oder Fused Silica(b). Die deutlichste Veränderung der Signalform wurde durch die Dispersion von Fused Silica (b) hervorgerufen. Mit zunehmender Frequenz tritt eine immer charakteristischere oszillierende Struktur auf. Dies ist vermutlich darauf zurückzuführen, dass der Brechungsindex dieses Materials bei abnehmender Wellenlänge nur geringe Änderungen aufweist. Bei CS_2 (a) hingegen führte die Dispersion oberhalb einer Frequenz von 0,5 zu einem Abfall der Amplitude und zu einer Unterdrückung der Oszillationen. Die Ursache für dieses Verhalten blieb unklar, da der Brechungsindex keine besonderen Auffälligkeiten zeigte.

Zusammenfassend äußert sich der Dispersionseffekt im Signal durch zusätzliche oszillierende Flanken des Spektrums. Dieses Verhalten ähnelt stark den Signalverzerrungen, die bei der Generierung von Spektren mit großen Δ -Werten auftreten. Selbst beim Spektrengenerator nach Formel 3.2 in Abschnitt 3.1.1 lässt sich ein solches Muster beobachten. Es tritt ab etwa $\Delta = 50$ auf.




Abbildung 3.24: Beispiel eines verzerrten Spektrums für $\Delta = 50 \mu\text{m}$. Die oszillierenden Signalanteile überlagern sich und erzeugen damit eine rauschähnliche Struktur.

Nach der Signaltheorie tritt dieses Phänomen aufgrund einer Verletzung des Nyquist-Kriteriums (Abschnitt 2.3.1) auf. Erfolgt die Diskretisierung über die Wellenlänge mit einem zu großen Schritt, kann die sich schnell ändernde Phasenabhängigkeit nicht korrekt abgebildet werden, was zu Verzerrungen führt. Um diese Grenze zu bestimmen, wird das Nyquist-Kriterium für Signale mit variabler Phase herangezogen (Formel 2.36). Dazu ist es erforderlich, die Ableitung des Arguments des Kosinusausdrucks (Gleichung 3.16), welcher das Signal beschreibt, zu berechnen.

$$f'(\lambda) = \frac{d}{d\lambda} \left(\frac{2\pi}{\lambda} \right) \cdot ((n(\lambda) - 1)l_n - \Delta) + \frac{2\pi}{\lambda} \cdot \frac{d}{d\lambda} ((n(\lambda) - 1)l_n - \Delta) \quad (3.17)$$

Die Ableitungen werden einzeln bestimmt.

$$\frac{d}{d\lambda} \left(\frac{2\pi}{\lambda} \right) = -\frac{2\pi}{\lambda^2} \quad (3.18)$$

$$\frac{d}{d\lambda} ((n(\lambda) - 1)l_n - \Delta) = l_n \cdot \frac{dn}{d\lambda} \quad (3.19)$$

Das resultierende Ausdruck lautet wie folgt.

$$f'(\lambda) = \frac{2\pi}{\lambda^2} \left(-((n(\lambda) - 1)l_n - \Delta) + \lambda \cdot l_n \cdot \frac{dn}{d\lambda} \right) \quad (3.20)$$

Der Ausdruck enthält die Ableitung des Wellenlängenabhängigen Brechungskoeffizienten. Als Beispiel wird das Glas N-BK-7 und die Abhängigkeit seines Brechungsindex herangezogen (Abbildung 3.21). Für diese Berechnung wurde das Material ausgewählt, da seine Dispersion nur einen geringen Einfluss auf das Signalspektrum hat. Die Ableitung wird numerisch auf Grundlage tabellarischer Daten berechnet und zur Analyse zusätzlich visualisiert (Abbildung 3.25).




Abbildung 3.25: Die Ableitung des Brechungskoeffizienten für N-BK-7 von der Wellenlänge

Die größten Änderungen des Brechungskoeffizienten treten im Bereich sehr kleiner Wellenlängen auf. Ab dem sichtbaren Spektralbereich nähert sich das Verhalten zunehmend dem linearen Verlauf an. Basierend auf dieser Berechnung wird nun die Ableitung der Phase für einen einzelnen Δ -Wert bestimmt. Dies ermöglicht eine Einschätzung, wie stark sich die Phase mit zunehmender Wellenlänge verändert.




Abbildung 3.26: Phasenableitung in Abhängigkeit von der Wellenlänge bei $\Delta = 22 \mu\text{m}$

Das Maximum der Phasenableitung tritt bei der minimalen Wellenlänge auf. Unter Anwendung des Nyquist-Kriteriums wird dieser Ableitungswert in einen konkreten Abtastschritt entlang der

Wellenlänge überführt. Hierfür ist die Berechnung der Phasenableitung für alle Δ -Werte erforderlich. Durch die Zusammenführung aller ermittelten Abtastschrittweite lässt sich die Tendenz der Veränderung des erforderlichen minimalen Wellenlängenschritts nachvollziehen (Abbildung 3.27).




Abbildung 3.27: Zulässige Änderung des Wellenlängenschritts gemäß Nyquist-Kriterium zur verzerrungsfreien Signalverarbeitung

Es zeigt sich, dass bereits bei einer spektralen Auflösung von wenigen Nanometern ($\delta\lambda_a \sim 0.002 \mu\text{m}$) die Verletzung des Nyquist-Kriteriums einsetzt, sobald der Weglängenunterschied Δ etwa $20 \mu\text{m}$ erreicht. Auf diese Weise wurde die theoretische Grenze für den Beginn der Signalverzerrung bestimmt. Wie bereits gezeigt (Abbildung 3.24), treten deutliche Verzerrungen erst bei $\Delta > 50$ auf, also oberhalb der zuvor berechneten theoretischen Grenze.

Die Anwendung einer Gauß-Funktion auf derartige Spektren verbessert die Lesbarkeit der verrauschten Daten, stößt jedoch an ihre Grenzen. Bei Δ -Werten über $170 \mu\text{m}$ beginnt aufgrund der geringen spektralen Auflösung und gemäß dem Nyquist-Theorem ein irreversibler Verlust nützlicher Signalinformationen. Der Abstand zwischen den Peaks nimmt kontinuierlich zu, während die Peaks selbst breiter werden. Es wird eine Auflösungsgrenze erreicht, bei der sich das Signal überlagert und erneut in rauschähnliche Strukturen übergeht.




Abbildung 3.28: Beispiel für die Erweiterung des Bereichs der Erzeugung unverzerrter Spektren durch Anwendung der Gauß-Funktion. a – simuliertes Spektrum mit Gauß-Filterung für $\Delta = 100 \mu\text{m}$, b – simuliertes Spektrum mit Gauß-Filterung für $\Delta = 170 \mu\text{m}$

Das Ergebnis kann ebenfalls verbessert werden, wenn eine Gauß-Funktion mit anderen Grenzen angewendet wird. Ausgehend vom Verlauf der zweiten Ableitung der Phase (Abbildung 3.21) erfolgt die geringste Änderung nach $2,0 \mu\text{m}$. Der Kosinus ändert sich ab diesem Bereich mit der niedrigsten Frequenz. In diesem Fall schneidet die angewandte Gauß-Funktion (ab $2,0 \mu\text{m}$ bis $2,5 \mu\text{m}$) den Großteil der hochfrequenten Komponenten ab, die das Spektrum verrauschen. Diese Maßnahme hat jedoch ihre Grenzen. Für Δ -Werte über $1000 \mu\text{m}$ beginnt der Aliasing-Effekt (Abbildung 2.12). Selbst unter Berücksichtigung der Gauß-Funktion, die hochfrequente Signalanteile abschwächt, ändert sich die Phase bei solchen Δ -Werten so schnell, dass die Abtastfrequenz nicht ausreicht, um das Signal korrekt zu erfassen. Die Spitzen im Fourier-Spektrum rücken näher zusammen. Dies zeigt, dass das Signal nun fehlerhaft erfasst wird, wodurch eine zuverlässige Bestimmung des realen Δ aus dem Spektrum nicht mehr möglich ist.




Abbildung 3.29: Demonstration des Aliasing-Effekts am Beispiel des Fourier-Spektrums bei $\Delta > 1000 \mu\text{m}$

3.1.3 Signalrauschen

Für eine vollständige physikalische Simulation müssen Rauschquellen berücksichtigt werden, die in jeder realen Messung unvermeidlich auftreten. Da der entwickelte Algorithmus die vom Detektor registrierte Intensität modelliert, werden potenzielle Detektorrauschen betrachtet. Das Rauschen wird als additiv angenommen, da es unabhängig vom simulierten Signal ist und sich lediglich zu diesem am Detektor addiert (Formel 3.1)

$$\varphi = \frac{2\pi}{\lambda} [(n(\lambda) - 1) \cdot l_n - \Delta] + \eta(\lambda)$$

Für die Simulation eignet sich insbesondere Flicker-Rauschen (siehe Abschnitt 2.3.3). In photosensitiven elektronischen Bauelementen entstehen aufgrund struktureller Imperfektionen kleine Fluktuationen der Leitfähigkeit, Temperatur und Potentiale. Die Überlagerung vieler unabhängiger langsamer Fluktuationen führt zu einem Rauschspektrum, das proportional zu $1/f$ ist, wobei die Amplitude bei niedrigen Frequenzen dominiert. Zusätzlich treten im Detektor thermische Rauschanteile auf, die durch ein Weißrauschmodell beschrieben werden; deren Amplitude ist jedoch in der Regel deutlich geringer als die des niederfrequenten $1/f$ -Rauschens (Rosa Rauschen).




Abbildung 3.30: Demonstration der spektralen Leistungen des simulierten weißen Rauschens (thermischer Anteil) und des rosa Rauschens ($1/f$ Flicker-Rauschanteil). Die spektrale Leistung ist in willkürlichen Einheiten (a.u.) nach Fourier-Transformation dargestellt.




Abbildung 3.31: Einfügen von Rauschen in die Simulation des Interferogramms.

Wie erwartet, führen die hinzugefügten Rauschanteile im Signal zu Fluktuationen im Bereich niedriger Frequenzen (Abbildung 3.31). Nach der Fourier-Transformation ähnelt der Effekt einer starken Dispersion: Die Oszillationen erscheinen dichter, überlagern sich und weisen eine erhöhte Amplitude auf (Abbildung 3.32a). Ein anderes Verhalten zeigt sich, wenn das Rauschen zu einem mit einer Gaußfunktion gefilterten Spektrum addiert wird (Abbildung 3.32b). Da das $1/f$ -Rauschen bei niedrigen Frequenzen dominiert, entsteht zwischen den Reflexionspeaks ein ausgeprägter breiter Peak. Bei erhöhter Rauschamplitude kann dieser mittlere Peak die gleiche Größenordnung wie die Reflexionspeaks erreichen.




Abbildung 3.32: Einfluss von Rauschen auf die Fourier-Spektren. a – Simulation des Spektrums mit Rauschen ohne Multiplikation mit einer Gaußfunktion, b – Simulation des Spektrums mit Rauschen und Multiplikation mit einer Gaußfunktion. Rauschamplitude – 0,4

3.1.4 Integration des deterministischen Ansatzes in CycleGAN




Abbildung 3.33: Schema der Implementierung des deterministischen Algorithmus in die Architektur von CycleGAN. G und F' – Transformationsfunktionen. Conv2d – Faltungsoperation, Flatten – Vektorisierung, Linear – vollständig verbundene Schicht.

Als Ergebnis der vorangegangenen Abschnitte wurde ein Algorithmus entwickelt, der Spektren auf Grundlage der Parameter des OCT-Systems generieren kann. Untersucht wird nun, wie dieser Algorithmus die Leistung der bereits getesteten Transformationsfunktion G (Abschnitt 3.1.1.1) beeinflusst. In der Architektur von CycleGAN werden der statistische G und der deterministische F' Ansatz kombiniert (Abbildung 3.33). Das zentrale Konzept besteht darin, dass die Vorhersagen des Netzwerks den Eingang des Netzwerks selbst beeinflussen. Im Unterschied zu Abschnitt 3.1.1.3, in dem zwei Netzwerke versuchten, sich gegenseitig an Eingangs- und Ausgangsdaten anzupassen, erhält das Netzwerk hier stets korrekte Spektren als Eingang. Der deterministische Algorithmus F' unterstützt somit den Trainingsprozess. Unter der Annahme eines eindeutigen, wahren Verfahrens zur Transformation spektraler Informationen in optische Parameter sollte der deterministische Algorithmus die statistische Lösung des CNN an dieses Transformationsergebnis annähern.




Abbildung 3.34: Ergebnisse nach dem Training des Neuralnetzwerks G im CycleGAN mit deterministischer Algorithmus («Epoch» = 25, «Learning rate» = 10^{-3}). Parameter des deterministischen Algorithmus: Strahlungsquelle – $[0,2-6,7 \mu\text{m}]$ mit einer Auflösung von 6 nm , Dispersionselement – Fused Silica mit einer linearen Größe von 1 cm , Gauß-Funktion als Filter mit Wirkungsbereich – $[1,2-2,0 \mu\text{m}]$, Rauschamplitude – $0,8$. Relative Vorhersagefehler $\ll 1\%$.

Zusammenfassend ist festzuhalten, dass das Transformationsnetzwerk G selbst bei Einbindung des deterministischen Ansatzes in den CycleGAN-Zyklus weiterhin in der Lage ist, mittels Faltungsoperationen den Wert der optischen Gangunterschieds Δ aus dem Fourier-Spektrum präzise zu reproduzieren (Abbildung 3.34). Die Erhöhung des Rauschpegels im Vergleich zur vorherigen Simulation (Abbildung 3.32) sowie die Verwendung von Fused Silica als Dispersionsmaterial hatten keinen Einfluss auf die Vorhersageergebnisse.

3.2 Anwendungsfall Tomographie

Die erzielten Ergebnisse für die Profilometrie lassen sich auf die Analyse der Tomographie erweitern. Tomographie stellt eine Methode zur Untersuchung der inneren Struktur von Objekten

dar, bei der eine schrittweise Abtastung der Schichten des Objekts erfolgt und anschließend Abbildungen dieser Schichten rekonstruiert werden. Wie im vorherigen Unterkapitel erwähnt, spiegeln die simulierten profilometrischen Spektren lediglich eine einfache Reflexion der elektromagnetischen Strahlung an der Oberfläche der Probe wider. Es wurde nicht von einer inneren Struktur der untersuchten Probe ausgegangen. Für die Tomographie ist hingegen das Vorhandensein einer zumindest teilweise geschichteten Struktur und von Inhomogenitäten erforderlich. Ein vereinfachtes physikalisches Modell zur Gewinnung des Spektrums einer solchen Probe wurde in Abschnitt 2.1.2 Fourierbereich-Weißlichtinterferometrie beschrieben.

$$E_{IS}(\omega) = E_R(\omega) + E_{P,0}(\omega) + \sum_{m=1}^N E_{P,m}(\omega)$$

3.2.1 Generierung von Daten

Bei der Herleitung von Formel 2.10 ist es erforderlich, sowohl die Amplitudenänderungen beim Durchgang durch die Schichten zu berücksichtigen als auch die Veränderungen des Phasenanteils des Signals differenzierter darzustellen. Die Entwicklung eines Algorithmus zur Simulation von Spektren für eine solche Probe von Grund auf, selbst unter Berücksichtigung von Vereinfachungen, ist eine aufwendige Aufgabe und erfordert eine umfangreiche Kalibrierung. Es wurde beschlossen, für die Simulation auf einen bereits entwickelten Algorithmus zur Tomographie zurückzugreifen. Für die Simulation der Spektren wurde das Demo-Skript des OCT-Simulators herangezogen, welches anhand eines synthetischen Objekts ein B-Scan-Bild unter Anwendung des OCT-Bildgebungsmodells erzeugt. Dieses Skript wurde von Sebastian Ruiz Lopera im Rahmen seiner Masterarbeit «Computational Aberration Correction in Optical Coherence Tomography with Phase-Unstable Systems» entwickelt[35].

Die Grundidee der Berechnung des von der Probe reflektierten Feldes (Formel 2.15) in diesem Skript wurde erweitert, um für die OCT relevante optische Parameter zu berücksichtigen, wie numerische Apertur, Sensitivität gegenüber Aberrationen und verschiedene Rauscharten (Abbildung 3.35). Die Generierung der Probenstruktur wurde ebenfalls stark erweitert: Es können nicht nur die Anzahl der Schichten, sondern auch die Inhomogenität ihrer Profile festgelegt werden. In der theoretischen Formel 2.15 wurde die Streuung der Strahlung im Material nicht berücksichtigt. Eine analytische Berücksichtigung der Streuung gestaltet sich schwierig, da hierfür die Verteilung der Streuer und ihre räumlichen Positionen beschrieben werden müssten, was einen umfangreichen mathematischen Apparat erfordert. Im Skript hingegen werden bei der Generierung der Struktur alle relevanten Parameter der Streuer definiert und deren Verteilung innerhalb der Schichten zufällig erzeugt. Unter Berücksichtigung der detaillierten physikalischen Prozesse des Lichts in den Materialien liegt der Schwerpunkt des Skripts darauf, realistischere OCT-Spektren zu erzeugen. Hierbei werden Mittelungen und Filter angewendet, wie sie üblicherweise in der praktischen OCT-Bildgebung eingesetzt werden (Abbildung 3.35).




Abbildung 3.35: Flussdiagramm des verwendeten Skripts zur Simulation OCT-Bilder. NA – Numerische Apertur, SNR – Signal-Rausch-Verhältnis, ρ – Dichte der Streuer, r – Radius der Streuer, n – Brechungsindex der Streuer

Im Skript von Sebastian Ruiz Lopera wird auch eine detaillierte Berücksichtigung der Polarisation und ihrer Veränderungen beim Durchgang durch das Material implementiert. Im Rahmen dieser Arbeit wird dies jedoch nicht genutzt, da die gewählten Bedingungen zur Beschreibung des elektrischen Feldes (Formel 2.4) in Kapitel «Theoretische Grundlagen» dies nicht vorsehen.




Abbildung 3.36: Ein Beispiel zur Visualisierung der Ergebnisse des Skripts von Sebastian Ruiz Lopera. a – Profilkarte der Rückstreuung für die geschichtete Struktur, b – OCT-B-Scan.

Für die Simulation wurde die Anzahl der Schichten auf 5 festgelegt, um eine akzeptabel komplexe Struktur analysieren zu können. Zudem wurden Unregelmäßigkeiten an den Schichtgrenzen definiert, um die Daten für die weitere Analyse zu diversifizieren. Bevor auf die OCT-Darstellungen eingegangen wird, ist zunächst die Generierung der Rückstreuungsprofi-

le von Interesse (Abbildung 3.36a). Im Unterschied zum B-Scan wird hierfür keine Fourier-Transformation verwendet. Für die Profilerstellung wird zunächst für jede Schicht eine zufällige Verteilung ρ punktförmiger Streuer modelliert. Basierend auf den zuvor festgelegten Radien R der Streuer und deren Brechungsindizes n_{sc} wird der Streuquerschnitt in der Rayleigh-Approximation[34] berechnet.

$$\sigma_s = \frac{8\pi}{3} (k)^4 R^6 \left(\frac{n_{sc}^2 - n_m^2}{n_{sc}^2 + 2n_m^2} \right)^2 \quad (3.21)$$

wobei R – der Radius der Teilchen-Streuer, k – die Wellenzahl im Medium, n_{sc} – Brechungsindex der Teilchen-Streuer, n_m – Brechungsindex der Schicht.

Analog zur Berechnung der Formel 2.15 wird die Summe der Dämpfungskoeffizienten a_m sowie der doppelte Durchgang ($2k_m d_m$) des Lichts durch das Material berücksichtigt. Abschließend erfolgt eine Korrektur für die numerische Apertur NA des simulierten Objektivs, die angibt, welcher Anteil des rückgestreuten Lichts tatsächlich erfasst wird.

$$f_{\text{back}}(\text{NA}) = 16\pi \frac{1}{\beta^3 + 3\beta + 4}, \quad \beta = 1 - \text{NA}^2 \quad (3.22)$$

Die Betrachtung eines solchen Profils ist wichtig, da dessen praktische Gewinnung schwierig ist und zahlreiche Messungen sowie eine aufwendige Nachbearbeitung der Daten erfordert[28]. Diese Profile stellen im Wesentlichen die tatsächlichen Informationen über die Struktur der Probe dar.




Abbildung 3.37: Rückstreuprofil eines Schnitts einer geschichteten Probe. Die Intensität des Signals im Rückstreuprofil wird in willkürlichen Einheiten (a.u.) angegeben. Die Einheiten sind nicht kalibriert und entsprechen nicht der absoluten Leistung.

Das Erzeugungsraster wird stets doppelt so groß wie die vorgegebene Auflösung angelegt, um bei Bedarf die erhöhte Anzahl an Schichten oder deren Breite zu berücksichtigen (Abbildung 3.37). Ein Abfallen der Intensität auf null bedeutet, dass die Streuverteilung darüber hinaus nicht definiert ist. Die Intensität jeder einzelnen Schicht hängt komplex von den ursprünglich festgelegten Parametern der Streuer ab.

Bezüglich der Generierung des OCT-B-Scans erfolgt zunächst die Berechnung der Interferogramme für die A-Scans (Abbildung 3.38). Unter Verwendung der berechneten Karte der Streuerverteilung im Material wird die Hin- und Rückausbreitung eines Gaußschen Strahls im Material berechnet. Trifft der Strahl direkt auf einen Streuer, ist der Einfluss auf die Intensität am größten und nimmt ab, wenn nur die Umgebung des Strahls betroffen ist. Das resultierende Interferogramm stellt eine Superposition der Beiträge vieler Streuer in den Schichten dar. Aufgrund der Phasenberücksichtigung ist dieses Interferogramm eine komplexe Funktion. Im Skript wird, analog zu praktischen Untersuchungen, nur der Realteil betrachtet, da genau dieser vom Detektor erfasst wird.




Abbildung 3.38: Simuliertes Interferogramm im Spektralraster im Wellenzahlraum k , das vom Spektrometer des OCT-Systems registriert wird.

Die Form des Interferogramms (Abbildung 3.38) zeigt deutlich die Anwendung einer Fensterfunktion – der Hanning-Funktion (Abbildung 3.39). Sie ähnelt stark einer Gauß-Verteilung, weist jedoch eine etwas breitere Kuppe auf.




Abbildung 3.39: Vergleich der Hanning-Fensterfunktion mit der Gauß-Funktion. Die Grenzen der Funktionen entsprechen den ursprünglich festgelegten Parametern des Quellspektrums $\Delta\lambda$

Die generierten Interferogramme stellen einen zentralen Bestandteil der weiteren Untersuchung dar. In der Fourierbereich-Weißlichtinterferometrie (Kapitel 2.1.2) wird zur Gewinnung von Informationen über die Probe die Fourier-Transformation der registrierten Intensitätsabhängigkeit von der Wellenlänge angewendet. Das Ergebnis ist eine komplexe Funktion, die die Amplitude der Reflektoren in verschiedenen Tiefen sowie Phaseninformationen über Verschiebungen enthält.

Bei realen Signalen genügt für die übliche Rekonstruktion der Struktur die Betrachtung der Amplitude (Formel 2.26). Die Phase (Formel 2.27) ist stark rauschempfindlich und wird daher in praktischen Studien zur Strukturanalyse [3], [26] oft nicht berücksichtigt, um die Analyse nicht zu verkomplizieren. Allerdings enthält die Phase wertvolle Informationen über die Verschiebung reflektierender Grenzflächen und Änderungen der optischen Weglänge. Die Amplitude informiert lediglich über die Position der Reflektoren in der Probe und deren Stärke. Die Phase hingegen liefert präzise Angaben über die Lage und Bewegung dieser Reflektoren im Raum und ist deutlich empfindlicher gegenüber Änderungen in der Probe als die Amplitude. Daher besteht das Ziel darin, diese Informationen nicht zu verwerfen und sie künftig auch beim Training neuronaler Netze zu nutzen.




Abbildung 3.40: Amplitude der Fourier-transformierten Interferogramm-Funktion




Abbildung 3.41: Phase der Fourier-transformierten Interferogramm-Funktion

Die Amplitudenprofile werden im Skript von Sebastian Ruiz Lopera zusammengeführt und einer Nachbearbeitung unterzogen, wie sie für OCT-Darstellungen üblich ist. Auf diese Weise entsteht ein B-Scan der geschichteten Struktur mit zufällig verteilten Streuern. Zur Veranschaulichung werden zusätzlich die resultierenden B-Scans sowohl der Amplitude als auch der Phase visualisiert (Abbildung 3.42).




Abbildung 3.42: a – Amplitudenkomponente des B-Scans basierend auf den Interferogrammen, b – Phasenkomponente des B-Scans

Wie bereits erwähnt, sind Phasendaten schwierig zu analysieren. Visuell lassen sich zwar die Schichten erkennen, jedoch ist das Bild durch hochfrequentes Rauschen gestört. Auch im Am-

plitudenscan sind zahlreiche Interferenz-Speckles sichtbar. Beide Bilder stellen Matrizen der Größe $[256 \times 512]$ dar, wobei jedes Element einen Intensitätswert besitzt.

Bevor erneut auf die in dieser Arbeit für die Profilometrie(3.1) bewährte CycleGAN-Architektur zurückgegriffen wird, soll zunächst überprüft werden, ob aus dem B-Scan einer Probe Informationen über deren Parameter gewonnen werden können. Dabei ist zu klären, ob diese Informationen teilweise oder vollständig extrahiert werden können. Ein wichtiger Punkt in der Untersuchung ist, dass die Phasenkomponente nicht verworfen werden darf und stets mit der Amplitude verknüpft sein muss. Die Parameter der Probengenerierung können als eindimensionaler Vektor $[1 \times 40]$ dargestellt werden, in dem die Werte aufgelistet sind. Dazu gehören die Schichtdicken, die Verteilung der Unregelmäßigkeiten, die Dichten ρ der Streuerpartikel, die Radien R der Streuerpartikel, der Brechungsindex n_{sc} der Streuerpartikel sowie die Dämpfungskoeffizienten a in den Schichten.

Die Transformation des B-Scans, der aus zwei miteinander verknüpften Bildern besteht, in einen eindimensionalen Vektor im Rahmen von CycleGAN ist problematisch, da die Dimensionen stark unterschiedlich sind. Zwei Matrizen der Größe $[256 \times 512]$ könnten zwar mittels Faltung zu einem eindimensionalen Vektor reduziert werden, dabei geht jedoch die räumliche Struktur vollständig verloren. Eine transponierte Faltung (Deconvolution) zur Wiederherstellung der ursprünglichen Matrizen aus einem sehr kleinen Vektor, zum Beispiel $[1 \times 40]$, ist unmöglich, da weder die ursprüngliche Anzahl an Elementen ($[2 \times 256 \times 512] = 262144$) noch deren korrekte Anordnung rekonstruiert werden kann. Unter diesen Umständen muss auf eine einfachere Analyse mittels neuronaler Netze zurückgegriffen werden – auf eine gewöhnliche Faltung. Diese erhält als Eingabe ein zweikanaliges B-Scan-Bild und liefert als Ausgabe einen eindimensionalen Vektor mit den entsprechenden Werten (Abbildung 3.43). Auf jede der beiden zweidimensionalen Matrizen wird ein dreischichtiges Faltungsneuronales Netzwerk angewendet, das die Dimension auf einen eindimensionalen Vektor reduziert, dabei die Anzahl der Kanäle bei der Faltung erhöht und Merkmale extrahiert. Die beiden resultierenden Vektoren von Phase und Amplitude werden mittels Konkatenation zusammengeführt, gefolgt von einer finalen Transformation über eine vollständig verbundene Schicht.




Abbildung 3.43: Modell zur Faltung der Amplituden- und Phasenteile des B-Scans zu einem eindimensionalen Vektor mit Parametern der Schichtgenerierung. Conv2D – Faltungsoperation für 2D. AdaptiveAvgPool2d – adaptives Mittelwert-Pooling für 2D. Flatten – Vektorisierung, Concatenation – Konkatenation. Linear – vollständig verbundene Schicht.

Für das Training wurden 100 verschiedene B-Scans mit geringfügigen Abweichungen der verschiedenen Parameter generiert. Alle Daten wurden analog zu Formel 3.1 normalisiert, um insbesondere rechenaufwendige Bildtransformationen zu erleichtern. Das Training nach 10 Epochen und «Lernrate» = 10^{-3} unter Verwendung der L1-Metrik ergab einen Verlustwert von 20%. Es zeigte sich, dass das erstellte Modell in der Lage ist, die Parameter auf Basis der beiden Bilder der Amplitude und Phase des B-Scans gut vorherzusagen (Abbildung 3.44).




Abbildung 3.44: Beispiel für den Vergleich der Vorhersagen des Faltungsmodells für Amplitude und Phase mit den tatsächlichen Parametern, die in einem eindimensionalen Vektor gespeichert sind.

Zur erneuten Nutzung der CycleGAN-Architektur werden die Ergebnisse des Skripts von Sebastian Ruiz Lopera herangezogen. Darin werden nicht nur OCT-B-Scans generiert, sondern auch eine Profilkarte der Rückstreuungsintensitätsprofile des Materials (Abbildung 3.31a). Diese Profilkarte stellt ein 2D-Bild dar und kann daher als eine der Domänen in die zyklische Struktur integriert werden. Die Faltungsoperation kann nun sowohl für die Vorwärts- als auch für die Rückwärts-Transformation angewendet werden. Als A-Domäne dienen die Amplituden-

und Phasenkomponente des B-Scans, wobei ihre gegenseitige Verknüpfung weiterhin erhalten bleibt (Abbildung 3.45). Die B-Domäne wird durch die Karten der Rückstreuprofile dargestellt, die mit denselben Parametern wie der B-Scan generiert wurden.




Abbildung 3.45: CycleGAN-Schema zur Transformation der Amplituden- und Phasenkomponente des OCT-B-Scans (A) in die Karte der Rückstreuprofile (B). J und Q bezeichnen die Funktionen zur Transformation der Daten von einer Domäne in die andere.

3.2.2 Transformation $J: A \rightarrow B$

Als Eingabe werden zwei Matrizen der Größe $[256 \times 512]$ verwendet. Diese werden einer Faltung unterzogen, bei der beide Kanäle durch den Filter bearbeitet werden, ohne dass sich ihre Größe ändert (Abbildung 3.46). Jedes Mal erweitert ein unterschiedlicher Faltungsfilter die Anzahl der Kanäle von 2 auf 64. Die Operation wird wiederholt, wobei in der zweiten Schicht die Anzahl der Feature-Maps auf 128 erhöht wird. Aufgrund der größeren Höhe des Ausgabebildes im Vergleich zu den Eingabebildern wird eine transponierte Faltung (transposed convolution) eingesetzt, um die räumliche Größe zu vergrößern. Anschließend erzeugt die Faltung am Ausgang, nach der Erweiterung der Kanalanzahl, ein einkanaliges Bild der Größe $[512 \times 512]$.




Abbildung 3.46: Schema der Funktion J zur Transformation der Amplituden- und Phasenkomponente des OCT-B-Scans in die Karte der Rückstreuprofile. Conv2d – Faltungsoperation, ConvTransposed2d – transponierte Faltungsoperation.

Die Ergebnisse des Netzwerktrainings selbst an 10 Bildpaaren von Amplitude und Phase waren bemerkenswert (Abbildung 3.47). Das Netzwerk rekonstruiert die Karte der Rückstreuprofile

nahezu perfekt.




Abbildung 3.47: Ergebnis der Funktion J. a – tatsächliches Rückstreuprofil, b – vorhergesagtes Profil.

3.2.3 Transformation $Q: B \rightarrow A$

Analog zur Funktion J wird zunächst die Anzahl der Kanäle des Eingabebildes der Größe $[512 \times 512]$ mittels Faltung erhöht. Nach zwei Faltungsoperationen, wenn die Anzahl der Merkmalskarten 128 erreicht hat, muss die Höhe des Datensatzs reduziert werden, da die Ausgabedaten der Amplituden- und Phasendaten nur halb so hoch sind wie die Profilkarte. In den finalen Faltungsschritten wird die Anzahl der Kanäle auf zwei reduziert, sodass am Ausgang zwei Bilder mit jeweils der Größe $[256 \times 512]$ erhalten werden.




Abbildung 3.48: Schema der Funktion Q zur Transformation der Karte der Rückstreuprofile in die Amplituden- und Phasenkomponente des B-Scans. Conv2d – Faltungsoperation.

Die Ergebnisse des Trainings waren uneinheitlich (Abbildung 3.44). Die rekonstruierten Abschnitte des B-Scans zeigen die korrekte Schichtverteilung, jedoch unterscheiden sich deren geometrische Abmessungen von den ursprünglichen. Ähnlich wie bei der Eingangskarte enthalten die vorhergesagten Amplituden- und Phasendaten im unteren Bereich eine Zone mit fehlenden Daten. Bezüglich der Amplitude hat das Faltungsneuronale Netzwerk die Speckles im Bild entfernt. Dies ist nachvollziehbar: Faltungsfilter erkennen stabile lokale Muster und unterdrücken gleichzeitig zufällige Signalfuktuationen. Infolgedessen sind hochfrequente Schwankungen, die für Speckles typisch sind, im Ausgangsbild nahezu nicht vorhanden, wodurch dieses im Vergleich zum Original geglätteter wirkt. Diese Eigenschaft wirkte sich jedoch negativ auf die Rekonstruktion der Phasendaten aus. Am Ausgang stellte sich die Phase lediglich als invertierte Version der Amplitude dar. Die Mittelung beraubte die Phase vollständig ihrer komplexen Struktur.




Abbildung 3.49: Ergebnis der Funktion Q. a – tatsächliche Amplitude des B-Scans, b – tatsächliche Phase des B-Scans, c – vorhergesagte Amplitude, d – vorhergesagte Phase.

3.2.4 Geschlossener Transformationszyklus(CycleGAN) - Kombination von J und Q

Die Zusammenführung in einen Zyklus hat die Ergebnisse des Trainings der Funktionen J und Q nicht verändert. Qualitativ zeigt sich dasselbe Bild: Die Rückstreuprofilkarte wird nahezu perfekt rekonstruiert, während die Rekonstruktion von Phase und Amplitude weiterhin die gleichen Einschränkungen aufweist wie bei einem einfachen Training außerhalb des Zyklus (Abbildung 3.44). Betrachtet man die Trainings- und Validierungskurven (Abbildung 3.50), lässt sich erkennen, dass das Lernverhalten der Modelle für die Funktionen J und Q unterschiedlich war. Obwohl der L1-Fehler(Formel 2.43) für die Funktion Q niedriger ausfällt, verdeutlicht dies erneut, dass die phasensensitive Komponente einen besonders präzisen Ansatz erfordert. Die neuronale Netzwerkstruktur sagt zwar die Amplitude zuverlässig voraus, doch selbst bei einem vollständigen Verlust der Phasenstruktur wird der Mittelwert als ausreichend nah an der Realität bewertet.




Abbildung 3.50: Ergebnisse des Trainings- und Validierungsprozesses der J- und Q-Netze im Zyklus. Epoch – ein vollständiger Durchlauf durch den gesamten Trainingsdatensatz. Loss – relative Abweichung der Vorhersagen von den tatsächlichen Werten.

4. Zusammenfassung der Ergebnisse

In dieser Arbeit wurde ein modifizierter Trainingsansatz für neuronale Netze zur Analyse von OCT-Signalen untersucht. Ziel war es, den Trainingsprozess so zu gestalten, dass die Modelle flexibel an Parameter der jeweiligen OCT-Systeme angepasst werden können. Dazu wurden in die Lernphase deterministisch physikalische Größen wie Detektorauflösung, Dispersion und zusätzliche Rauschanteile integriert. Der hybride Ansatz erweitert damit, wie es bereits demonstriert wurde in anderen Berichten der Anwendung von ML[45],[1], das statistische Fundament des maschinellen Lernens durch physikalische Gesetzmäßigkeiten. Als Basisarchitektur wurde CycleGAN gewählt, das Transformationen zwischen zwei Datendomänen ermöglicht. Zur Untersuchung wurde primär die eindimensionale Profilometrie herangezogen, da deren Simulation und Kalibrierung vergleichsweise einfach ist. Unter Anwendung interferometrischer Gleichungen wurde ein Algorithmus (Implementiert in Python) zur Generierung von Spektren in Abhängigkeit von der optischen Wegdifferenz Δ entwickelt. Die Simulationsparameter wurden separat gespeichert, sodass zwei Domänen entstanden: A – Spektrum und B – Generationsparameter. Faltungsnetzwerke zeigten eine hohe Genauigkeit bei der Vorhersage von Δ aus Spektren; Schwierigkeiten traten lediglich bei sehr kleinen $\Delta (< 10 \mu m)$ auf. Diese konnten durch Multiplikation der Interferogramme mit einer gaußschen Funktion, angepasst an die Breite der simulierten Lichtquelle, behoben werden (Abschnitt 3.1.1.3). Die inverse Transformation von Δ zu Spektren rekonstruierte die Position der Peaks zuverlässig, jedoch wurden Intensität und Oszillationsstruktur, insbesondere im niederfrequenten Bereich, nicht präzise wiedergegeben. Zur Annäherung an reale Bedingungen wurden Dispersion und Rauschen berücksichtigt. Während die Dispersion nur moderaten Einfluss hatte, stellte das Hinzufügen von Rauschen eine erhebliche Herausforderung für die Vorhersagegenauigkeit dar. Nach separatem Training der einzelnen Transformationen wurden diese in einer CycleGAN-Struktur kombiniert. Die Ergebnisse unterschieden sich nur geringfügig von den separat trainierten Modellen. Wurde in dieser Architektur die Transformation von Δ zu Spektren durch den deterministischen Algorithmus ersetzt, konnte das Faltungsnetz Δ -Werte aus Spektren sehr präzise rekonstruieren (Fehler $< < \%$). Damit wurde eine CycleGAN-Variante geschaffen, die flexibel für verschiedene Quellenbereiche und Set-up-Parameter einsetzbar ist. Zusätzlich wurde der Ansatz auf OCT-B-Scans übertragen (Abschnitt 3.24). Mithilfe eines externen Generators wurden realistische B-Scans verschiedener Schichtstrukturen erzeugt, die sowohl Scans als auch Profile des Rückstreuverhaltens lieferten. Dadurch konnten erneut zwei Domänen gebildet werden: A – OCT-B-Scan und B – Intensitätsprofil der Rückstreuung. Die Faltungsnetzwerke zeigten eine mittlere Genauigkeit für den amplitudenbasierten B-Scan-Anteil, da alle Spektren gemittelt wurden, jedoch wurden die Grenzen präzise vorhergesagt. Die Vorhersage der Rückstreuprofilkarte erfolgte exakt, eins zu eins mit den Referenzwerten. Die phasenbasierte Komponente hingegen wurde stark geglättet, sodass ihre komplexe Struktur vollständig verloren ging.

5.Ausblick

Das entwickelte Modell, das einen deterministischen, physikbasierten Ansatz mit einem statistischen Ansatz des maschinellen Lernens kombiniert, hat sein Potenzial unter Beweis gestellt. Dies hat den Lernprozess nicht gestört, sondern ihn vielmehr ergänzt und flexibler gemacht, so dass eine Anpassung an unterschiedliche Datensätze sich als möglich erwies. Der demonstrierte Algorithmus für die Profilometrie lässt sich auch auf die Verarbeitung von B- oder C-Scans erweitern. Komplexer wird lediglich der deterministische Teil des Algorithmus, der zur Datengenerierung entwickelt werden muss. Um diesen möglichst realitätsnah zu gestalten, müssen sämtliche optischen Effekte mit höher Akkurazität berücksichtigt werden: Mehrfachreflexionen, Streuung, Absorption, Phasenverschiebungen sowie Polarisation. Infolgedessen wird auch das Training des neuronalen Netzes anspruchsvoller und erfordert eine präzisere Abstimmung, um eine exakte Reproduktion der Daten zu erreichen. Darüber hinaus werden leistungsfähigere Rechenressourcen benötigt, ebenso wie Optimierungskonzepte zur Reduzierung der zeitaufwändiger Berechnungen, damit die entwickelten Algorithmen in praktischen Anwendungen einsetzbar sind.

Literatur

- [1] Anonymous. “Hybrid deep-learning and physics-based neural network for programmable optical phase conjugation”. In: Advanced Photonics Nexus 3.5 (2021), S. 056003. 10.1117/1.APN.3.5.056003.
- [2] Silke Aumann, Sabine Donner, Jörg Fischer und Frank Müller. “Optical Coherence Tomography (OCT): Principle and Technical Realization”. In: Handbook of Optical Coherence Tomography. Cham, Switzerland: Springer, 2020. Kap. 3. 10.1007/978-3-030-16638-0_3.
- [3] Jennifer Barton und Steve Stromski. “Flow measurement without phase information in optical coherence tomography images”. In: Optics Express 13.14 (Juli 2005), S. 5234–5239. 10.1364/OPEX.13.005234. <https://doi.org/10.1364/OPEX.13.005234>.
- [4] E. B. Baum und D. Haussler. “What size net gives valid generalization?” In: Neural Computation 1.1 (1989), S. 151–160. 10.1162/neco.1989.1.1.151.
- [5] Rami Bommarreddi. “Applications of Optical Interferometer Techniques for Precision Measurements of Changes in Temperature, Growth and Refractive Index of Materials”. In: Technologies 2.2 (Mai 2014). License: CC BY, S. 54–75. 10.3390/technologies2020054.
- [6] Max Born und Emil Wolf. *Principles of Optics: Electromagnetic Theory of Propagation, Interference and Diffraction of Light*. 7th. Cambridge: Cambridge University Press, 1999. ISBN: 978-0521642221.
- [7] Shelby Bradford. “Artificial Neural Networks: Learning by Doing”. In: The Scientist (2024). <https://www.the-scientist.com/artificial-neural-networks-learning-by-doing-71687>.
- [8] Ankit Butola, Dilip K. Prasad, Azeem Ahmad, Vishesh Dubey, Darakhshan Qaiser, Anurag Srivastava, Paramsivam Senthilkumaran, Balpreet Singh Ahluwalia und Dalip Singh Mehta. “Deep learning architecture "LightOCT" for diagnostic decision support using optical coherence tomography images of biological samples”. In: Biomedical Optics Express 11.1 (2020), S. 1–12. 10.1364/BOE.395487.
- [9] F. Cheng und K.-C. Fan. “High-Resolution Angle Measurement Based on Michelson Interferometry”. In: Physics Procedia 22 (2011), S. 401–407. 10.1016/j.phpro.2011.06.118.
- [10] F. R. Connor. “Elektronisches Rauschen”. In: Rauschen: Zufallssignale, Rauschmessung und -analyse. Hrsg. von F. R. Connor. Wiesbaden: Springer Vieweg, 2007, S. 53–65. 10.1007/978-3-322-83035-7_4.
- [11] J. Emile, P. Dupont und R. Martin. “Naked Eye Picometer Resolution in a Michelson Interferometer Using Conjugated Twisted Beams”. In: Optics Letters 45.12 (2025), S. 3456–3460. 10.1364/OL.45.003456.

- [12] Christoph R. Englert, John M. Harlander, Kenneth D. Marr, Brian J. Harding, Jonathan J. Makela und Tori Fae. *Michelson Interferometer for Global High-Resolution Thermospheric Imaging (MIGHTI): On-Orbit Wind Observations: Data Analysis and Instrument Performance*. Techn. Ber. NASA Technical Reports Server, 2023. 10.1007/s11214-023-00971-1. <https://ntrs.nasa.gov/citations/10590861523803>.
- [13] A. F. Fercher, W. Drexler, C. K. Hitzenberger und T. Lasser. “Optical coherence tomography – principles and applications”. In: Reports on Progress in Physics 66.2 (2002), S. 239–303. 10.1088/0034-4885/66/2/306.
- [14] Maurice Fréchet. “Sur quelques points du calcul fonctionnel”. In: Rendiconti del Circolo Matematico di Palermo 22.1 (1906). Section introducing the definition of a metric space, S. 4–6. 10.1007/BF03018603.
- [15] James G. Fujimoto, Costas Pitris, Sandra A. Boppart und Mark E. Brezinski. “Optical coherence tomography: an emerging technology for biomedical imaging and optical biopsy”. In: Neoplasia 2.1–2 (2000), S. 9–25. 10.1038/sj.neo.7900071.
- [16] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville und Yoshua Bengio. “Generative Adversarial Nets”. In: Advances in Neural Information Processing Systems (NeurIPS). Bd. 27. 2014, S. 2672–2680.
- [17] Andreas Habring und Martin Holler. “Neural-network-based regularization methods for inverse problems in imaging”. In: arXiv preprint arXiv:2312.14849 (2023). <https://arxiv.org/abs/2312.14849>.
- [18] Christiaan Huygens. *Traité de la lumière (Treatise on Light)*. Leiden: Pierre et Hermann Luchtmans, 1690.
- [19] Konrad Kopitzki und Peter Herzog. *Einführung in die Festkörperphysik*. 4. Aufl. Teubner Studienbücher Physik. Wiesbaden: Vieweg und Teubner Verlag, 2002, S. 484. ISBN: 978-3-322-91792-8.
- [20] Guy Lamouche, Marc L. Dufour, Mark Hewko u. a. “Using optical coherence tomography to optimize Mohs micrographic surgery for basal cell carcinoma”. In: Scientific Reports 14.1 (2024), S. 2345. 10.1038/s41598-024-53457-7.
- [21] Guy Lamouche, Marc L. Dufour, Mark Hewko, Michael Sowa u. a. “Intravascular optical coherence tomography on a beating heart model”. In: Journal of Biomedical Optics 15.4 (Juli 2010), S. 046023. 10.1117/1.3475960. <https://pubmed.ncbi.nlm.nih.gov/20515171/>.
- [22] S. M. Lee, J. H. Lee, Y. J. Kim u. a. “Enhanced penetration depth in optical coherence tomography and multimodal optical clearing techniques”. In: Scientific Reports 13 (2023), S. 48876. 10.1038/s41598-023-48876-x. <https://www.nature.com/articles/s41598-023-48876-x>.

- [23] Peter Lehmann, Stanislav Tereschenko und Weichang Xie. “Fundamental aspects of resolution and precision in vertical scanning white-light interferometry”. In: *Surface Topography: Metrology and Properties* 4.2 (2016), S. 024004. 10.1088/2051-672X/4/2/024004.
- [24] Flora Li und Arokia Nathan. *CCD Image Sensors in Deep-Ultraviolet: Degradation Behavior and Damage Mechanisms*. Berlin, Heidelberg: Springer, 2005. ISBN: 978-3-642-06152-3.
- [25] Ruilong Ling, Waleed Tahir, Hsing-Ying Lin und Lei Tian. “High-throughput intensity diffraction tomography with a computational microscope”. In: *Biomedical Optics Express* 9.5 (2018), S. 2130–2141. 10.1364/BOE.9.002130.
- [26] Gangjun Liu, Lidek Chou, Wangcun Jia, Wenjuan Qi, Bernard Choi und Zhongping Chen. “Intensity-based modified Doppler variance algorithm: application to phase instable and phase stable optical coherence tomography systems”. In: *Optics Express* 19.12 (Mai 2011). License: CC BY-NC-ND 3.0, S. 11429–11440. 10.1364/OE.19.011429. <https://doi.org/10.1364/OE.19.011429>.
- [27] Hendrik Antoon Lorentz. “The Theory of Electrons and Its Applications to the Phenomena of Light and Radiant Heat”. In: Bd. XXIX. B.G. Teubner’s Sammlung von Lehrbüchern auf dem Gebiete der mathematischen Wissenschaften mit Einschluss ihrer Anwendungen. Lectures delivered at Columbia University, New York, March–April 1906, 332 p. Leipzig und New York: B.G. Teubner, 1909.
- [28] Alexander L. Matveyev, Lev A. Matveev, Aleksandr A. Moiseev, Alexander A. Sovetsky, Grigory V. Gelikonov und Vladimir Y. Zaitsev. “Simulating scan formation in multimodal optical coherence tomography: angular-spectrum formulation based on ballistic scattering of arbitrary-form beams”. In: *Biomedical Optics Express* 12.12 (2021), S. 7571–7589. 10.1364/BOE.444273.
- [29] James Clerk Maxwell. “A Dynamical Theory of the Electromagnetic Field”. In: *Philosophical Transactions of the Royal Society of London* 155 (1865), S. 459–512. <https://doi.org/10.1098/rstl.1865.0008>.
- [30] A. A. Michelson und E. W. Morley. “On the relative motion of the Earth and the luminiferous ether”. In: *American Journal of Science* s3-34.203 (1887), S. 333–345. 10.2475/ajs.s3-34.203.333.
- [31] Frederick H. Mies. “Configuration Interaction Theory. Effects of Overlapping Resonances”. In: *Physical Review* 175 (1968), S. 164–176. 10.1103/PhysRev.175.164.
- [32] Ihab S. Mohamed. “Detection and Tracking of Pallets using a Laser Rangefinder and Machine Learning Techniques”. Magisterarb. European Master on Advanced Robotics (EMARO+), Sep. 2017. 10.13140/RG.2.2.30795.69926.

- [33] F. Prati, E. Regar, G. S. Mintz u. a. “Expert review document part 2: Methodology, terminology and clinical applications of optical coherence tomography for the assessment of interventional procedures”. In: *European Heart Journal* 33.20 (Mai 2012), S. 2513–2520. 10.1093/eurheartj/ehs095.
- [34] John William Strutt (Lord Rayleigh). “On the light from the sky, its polarization and colour”. In: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*. 4. Ser. 41.271 (1871), S. 107–120. 10.1080/14786447108640479.
- [35] Sebastian Ruiz-Lopera, René Restrepo, Carlos Alfredo Cuartas-Vélez, Néstor Uribe-Patarroyo und et al. “Computational adaptive optics in phase-unstable optical coherence tomography”. In: *Optics Letters* 45.21 (2020), S. 5982–5985. 10.1364/OL.401283. <https://doi.org/10.1364/OL.401283>.
- [36] Santosh Kumar Sahu, Anil Mokhade und Neeraj Dhanraj Bokde. “An Overview of Machine Learning, Deep Learning, and Reinforcement Learning-Based Techniques in Quantitative Finance: Recent Progress and Challenges”. In: *Applied Sciences* 13.3 (2023), S. 1956. 10.3390/app13031956. <https://www.mdpi.com/2076-3417/13/3/1956>.
- [37] D. Schmidl, A. Garhofer und R. Schmetterer. “Optical Coherence Tomography in Ophthalmology: Applications and Clinical Impact”. In: *Medical Sciences* 6.12 (2018), S. 2114. 10.3390/medsci6122114. <https://doi.org/10.3390/medsci6122114>.
- [38] Wilhelm Sellmeier. “Ueber die durch die Aetherschwingungen erregten Mitschwingungen der Körpertheilchen und deren Rückwirkung auf die ersteren, besonders zur Erklärung der Dispersion und ihrer Anomalien”. In: *Annalen der Physik* 223.11 (1871), S. 386–403. 10.1002/andp.18722231105.
- [39] Claude E. Shannon. “Communication in the Presence of Noise”. In: *Proceedings of the IRE* 37.1 (1949), S. 10–21. 10.1109/JRPROC.1949.232969.
- [40] P. N. Suganthan u. a. “Artificial Neural Networks Based Optimization Techniques: A Review”. In: *Electronics* 10.21 (2021), S. 2689. 10.3390/electronics10212689.
- [41] A. N. Tikhonov und V. Y. Arsenin. *Solutions of Ill-Posed Problems*. Hrsg. von Fritz John. English translation of the Russian original: *Metody resheniya nekorrektnykh zadach*, Nauka, Moscow, 1979. Distributed by Wiley, New York. Washington, DC: Winston und Sons, 1977.
- [42] Pete H. Tomlins, Jordi Lopez, Karl Alvarez und Adina T. Michael-Titus. “Heart rate sensitive optical coherence angiography”. In: *Proceedings of SPIE, Dynamics and Fluctuations in Biomedical Photonics XV*. Bd. 10493. Bellingham, WA: SPIE, 2018, 104930G. 10.1117/12.2317602.
- [43] Giovanni J. Ughi u. a. “Automatic assessment of stent neointimal coverage by intravascular optical coherence tomography”. In: *European Heart Journal – Cardiovascular Imaging* 15.2 (2014), S. 195–200. 10.1093/ehjci/jet174.

- [44] Vladimir N. Vapnik und Alexey Ya. Chervonenkis. “On the uniform convergence of relative frequencies of events to their probabilities”. In: *Theory of Probability and Its Applications* 16.2 (1971), S. 264–280.
- [45] Mengyuan Wang, Jianing Mao, Hang Su, Yuye Ling, Chuanqing Zhou und Yikai Su. “Physics-guided deep learning-based real-time image reconstruction of Fourier-domain optical coherence tomography”. In: *Biomedical Optics Express* 13.9 (2022), S. 4860–4875. 10.1364/BOE.454321.
- [46] Maciej Wojtkowski, Vivek J. Srinivasan, T. H. Ko, James G. Fujimoto, A. Kowalczyk und Jay S. Duker. “Ultrahigh-resolution, high-speed, Fourier domain optical coherence tomography and methods for dispersion compensation”. In: *Optics Express* 12.11 (2004), S. 2404–2422. 10.1364/OPEX.12.002404.
- [47] J. C. Wyant und K. Creath. “Advances in interferometric optical profiling”. In: *International Journal of Machine Tools and Manufacture* 32.1-2 (1992), S. 5–10. 10.1016/0890-6955(92)90005-N.
- [48] Shuming Yang und Guofeng Zhang. “A review of interferometry for geometric measurement”. In: *Measurement Science and Technology* 29.10 (2018), S. 102001. 10.1088/1361-6501/aad732.
- [49] Thomas Young. “The Bakerian Lecture: Experiments and Calculations Relative to Physical Optics”. In: *Philosophical Transactions of the Royal Society of London* 94.Part I and II (1804), S. 1–16. 10.1098/rstl.1804.0001.
- [50] Marco Zeppieri u. a. “Optical Coherence Tomography (OCT): A Brief Look at the Uses and Technological Evolution of Ophthalmology”. In: *Medicina* 59.12 (2023), S. 2114. 10.3390/medicina59122114. <https://doi.org/10.3390/medicina59122114>.
- [51] Y. Zhang u. a. “State-of-the-art in artificial neural network applications: A survey”. In: *Journal of King Saud University - Computer and Information Sciences* 34.5 (2022), S. 2656–2672. 10.1016/j.jksuci.2020.12.009.
- [52] H. Zhao und R. J. Cooper. “Review of recent progress toward a fiberless, whole-scalp diffuse optical tomography system”. In: *Journal of Biomedical Optics* 22.9 (2017), S. 091305. 10.1117/1.JBO.22.9.091305. <https://doi.org/10.1117/1.JBO.22.9.091305>.
- [53] Y. Zhao, D. T. Delpy und M. Cope. “A systematic investigation of reflectance diffuse optical tomography”. In: *Journal of Biomedical Optics* 19.2 (2014), S. 026003. 10.1117/1.JBO.19.2.026003. <https://doi.org/10.1117/1.JBO.19.2.026003>.
- [54] Jun-Yan Zhu, Taesung Park, Phillip Isola und Alexei A. Efros. “Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks”. In: (2017), S. 2242–2251. 10.1109/ICCV.2017.244.

6.Anhang

Code für CycleGAN mit deterministischem Algorithmus:

```

1      import torch
2      import os
3      import torch.nn as nn
4      import torch.optim as optim
5      import matplotlib.pyplot as plt
6      import numpy as np
7      from torch.utils.data import Dataset, DataLoader
8      import re
9      from torchvision import models
10     import torch.optim as optim
11     from pathlib import Path
12     import pandas as pd
13     from scipy import signal
14     from scipy.interpolate import interp1d
15     import torch.nn.functional as F
16     a_train_path = Path("data/train/A_G_D")
17     b_train_path = Path("data/train/B_G_D/values_of_steps.txt")
18     a_valid_path = Path("data/train/A_G_D")
19     b_valid_path = Path("data/train/B_G_D/values_of_steps.txt")
20     #####_AtoB-MODEL_#####
21     class Conv1DModel(nn.Module):
22     def __init__(self):
23     super(Conv1DModel, self).__init__()
24     self.conv1 = nn.Conv1d(1, 16, kernel_size=5, stride=1,
25         padding=2)
26     self.relu = nn.ReLU()
27     self.conv2 = nn.Conv1d(16, 32, kernel_size=5, stride=1,
28         padding=2)
29     dummy_input = torch.randn(1, 1, 1010)
30     with torch.no_grad():
31     dummy_output = self.conv2(self.relu(self.conv1(dummy_input)))
32     self.flattened_size = dummy_output.view(1, -1).size(1)
33     self.fc = nn.Linear(self.flattened_size, 1)
34     def forward(self, x):
35     x = self.relu(self.conv1(x))
36     x = self.relu(self.conv2(x))
37     x = x.view(x.size(0), -1) # Flatten
38     x = self.fc(x)
39     return x.squeeze(1)

```



```

#####Determ-Model#####
def g(omega, omega_0, sigma):
    return np.exp(-0.5 * ((omega - omega_0)/sigma)**2)
def fft(x, y):
    dx = x[1] - x[0]
    f_nq = 0.5 / dx
    n = len(x)
    f = np.fft.fftshift(np.fft.fftfreq(n, d=dx))
    s_fft = np.fft.fftshift(np.fft.fft(y))
    return f, s_fft
class SpectrumGenerator:
    def __init__(self, wl_file='Fused_silica.csv', th=1e
        -3, noise_scale=0.8, white_scale=0.05):
        self.th = th
        self.noise_scale = noise_scale
        self.white_scale = white_scale
        self.c = 3e8
        df = pd.read_csv(wl_file, decimal=".", delimiter=',')
            [:101]
        wl = df['wl'].values.astype(float)
        n = df['n'].values.astype(float)
        self.wl_new = np.linspace(wl.min(), wl.max(), 10 *
            len(wl))
        n_f = interp1d(wl, n, kind='cubic')
        self.n = n_f(self.wl_new)
        omega_min = 2 * np.pi * self.c / (2000e-9)
        omega_max = 2 * np.pi * self.c / (1200e-9)
        self.omega_0 = (omega_max + omega_min) / 2
        self.sigma = (omega_max - omega_min) / 8
        self.omega = 2 * np.pi * self.c / (self.wl_new * 1e
            -6)
        self.g_vals = g(self.omega, self.omega_0, self.sigma)
        N = len(self.wl_new)
        white = np.random.normal(0, 1, N) * self.white_scale
        b, a = signal.butter(1, 0.1, 'low')
        pink_noise = signal.lfilter(b, a, white)
        pink_noise /= np.std(pink_noise)
        pink_noise = pink_noise * (self.wl_new - self.wl_new.
            min()) / (self.wl_new.max() - self.wl_new.min())
        self.pink_noise = pink_noise
        self.omega_uniform = np.linspace(omega_min, omega_max
            , len(self.wl_new))
def generate(self, z):

```

```

75         s_n_z_current = np.cos((((self.n - 1) * self.th - z)
76             * 2 * np.pi / self.wl_new)) * self.g_vals
77         s_n_z_noisy = s_n_z_current + self.noise_scale * self
78             .pink_noise
79         f_sn, s_fft_n = fft(self.omega_uniform, s_n_z_noisy)
80         s_fft_n = np.abs(s_fft_n)
81         s_fft_n /= (s_fft_n.max() + 1e-8)
82         return f_sn, np.abs(s_fft_n)
83     #####_DATASET-CLASS_#####
84     class FourierDatasetDeterministic(torch.utils.data.Dataset):
85         def __init__(self, a_domain_path, b_values_path,
86             spectrum_generator):
87             self.spectrum_generator = spectrum_generator
88
89             self.b_values = np.loadtxt(b_values_path) #
90                 shape: (num_samples,)
91
92             a_files = [f for f in os.listdir(
93                 a_domain_path) if f.endswith('.txt')]
94
95             def extract_number(filename):
96                 return float(filename.split("[")[1].split("]"
97                     )[0])
98
99             a_files_sorted = sorted(a_files, key=
100                 extract_number)
101             self.a_paths = [os.path.join(a_domain_path, f
102                 ) for f in a_files_sorted]
103
104             def __len__(self):
105                 return len(self.a_paths)
106
107             def __getitem__(self, idx):
108
109                 spectrum = np.loadtxt(self.a_paths[idx])
110                 spectrum = (spectrum - spectrum.min()) / (
111                     spectrum.max() - spectrum.min() + 1e-8)
112                 if spectrum.ndim == 1:
113                     spectrum = spectrum.reshape(1, -1)
114
115                 z_value = self.b_values[idx] / 100
116                 _, b_spectrum = self.spectrum_generator.
117                     generate(z_value * 100)

```

```

108
109         return (
110             torch.tensor(spectrum, dtype=torch.float32),
111             torch.tensor(z_value, dtype=torch.float32),
112             torch.tensor(z_value, dtype=torch.float32).
113                 view(-1, 1),
114             torch.tensor(b_spectrum, dtype=torch.float32)
115         ),
116         os.path.basename(self.a_paths[idx])
117     )
118
119 # =====
120 # TRAINING FUNCTION
121 # =====
122 def train_cycleGAN_deterministic(
123     a_to_b_model,
124     spectrum_generator,
125     train_dataset,
126     val_dataset,
127     num_epochs=30,
128     batch_size=8,
129     lr=1e-3,
130     device="cuda" if torch.cuda.is_available() else "cpu"
131 ):
132     a_to_b_model = a_to_b_model.to(device)
133     optimizer_AtoB = optim.Adam(a_to_b_model.parameters()
134                                  , lr=lr)
135     mse_loss = nn.MSELoss()
136     l1_loss = nn.L1Loss()
137
138     train_loader = DataLoader(train_dataset, batch_size=
139                               batch_size, shuffle=True)
140     val_loader = DataLoader(val_dataset, batch_size=
141                             batch_size, shuffle=False)
142
143     history = {"train_total": [], "train_cycle": [], "
144               "val_total": [], "val_cycle": []}
145
146     for epoch in range(1, num_epochs + 1):
147         a_to_b_model.train()
148         train_total_loss, train_cycle_loss = 0, 0
149
150         for spectra, b_value, b_value_2d, b_spectrum,
151             _ in train_loader:

```

```

143     # (batch, 1, 1010) ---
144     if spectra.ndim == 2:
145         spectra = spectra.unsqueeze(1)
146     spectra, b_value, b_value_2d = spectra.to(
147         device), b_value.to(device), b_value_2d.to(
148             device)
149     b_spectrum = b_spectrum.to(device)
150
151     # ----- Forward A->B -----
152     pred_b = a_to_b_model(spectra) # A -> B
153
154     # ----- Deterministic B->A -----
155     b_to_a_spectra = []
156     for pb in pred_b.detach().cpu().numpy():
157         _, recon_spectrum =
158             spectrum_generator.generate(pb.
159                 item() * 100)
160         b_to_a_spectra.append(recon_spectrum)
161     recon_a = torch.tensor(np.stack(
162         b_to_a_spectra), dtype=torch.float32).
163         unsqueeze(1).to(device)
164
165     # ----- Forward cycle -----
166     pred_b_from_true = a_to_b_model(recon_a)
167     # ----- Losses -----
168     loss_ab = mse_loss(pred_b, b_value)
169         # A->B supervised
170     loss_ba = l1_loss(recon_a, spectra)
171         # B->A supervised
172     loss_cycle = mse_loss(pred_b_from_true,
173         b_value) + l1_loss(recon_a, spectra)
174     total_loss = loss_ab + loss_ba + 0.5 *
175         loss_cycle
176
177     optimizer_AtoB.zero_grad()
178     total_loss.backward()
179     optimizer_AtoB.step()
180
181     train_total_loss += total_loss.item()
182     train_cycle_loss += loss_cycle.item()
183
184     # ----- Validation -----
185     a_to_b_model.eval()
186     val_total_loss, val_cycle_loss = 0, 0

```

```

176         with torch.no_grad():
177             for spectra, b_value, b_value_2d, b_spectrum,
178                 _ in val_loader:
179                 if spectra.ndim == 2:
180                     spectra = spectra.unsqueeze(1)
181                     spectra, b_value, b_value_2d =
182                         spectra.to(device), b_value.to(
183                             device), b_value_2d.to(device)
184                     b_spectrum = b_spectrum.to(device)
185
186                     pred_b = a_to_b_model(spectra)
187
188                     # Deterministic B->A
189                     b_to_a_spectra = []
190                     for pb in pred_b.detach().cpu().numpy
191                         ():
192                         _, recon_spectrum =
193                             spectrum_generator.
194                                 generate(pb.item() * 100)
195                     b_to_a_spectra.append(recon_spectrum)
196                     recon_a = torch.tensor(np.stack(
197                         b_to_a_spectra), dtype=torch.
198                             float32).unsqueeze(1).to(device)
199
200                     pred_b_from_true = a_to_b_model(
201                         recon_a)
202
203                     loss_ab = mse_loss(pred_b, b_value)
204                     loss_ba = l1_loss(recon_a, spectra)
205                     loss_cycle = mse_loss(
206                         pred_b_from_true, b_value) +
207                         l1_loss(recon_a, spectra)
208                     total_loss = loss_ab + loss_ba + 0.5
209                         * loss_cycle
210
211                     val_total_loss += total_loss.item()
212                     val_cycle_loss += loss_cycle.item()
213
214     train_total_loss /= len(train_loader)
215     train_cycle_loss /= len(train_loader)
216     val_total_loss /= len(val_loader)
217     val_cycle_loss /= len(val_loader)

```

```
207
208         history["train_total"].append(train_total_loss)
209         history["train_cycle"].append(train_cycle_loss)
210         history["val_total"].append(val_total_loss)
211         history["val_cycle"].append(val_cycle_loss)
212
213         print(f"Epoch {epoch}/{num_epochs} | Train Total: {
                train_total_loss:.4f} | Val Total: {val_total_loss
                :.4f}")
214
215     torch.save(a_to_b_model.state_dict(), "
        AtoB_model_deterministic_1.pth")
216     print("AtoB saved as AtoB_model_deterministic.pth")
217
218     return history
```